Apuntes de Estadística

Análisis Multivariante

Curso 2025–2026

Temas 1–4: introducción, distribuciones multivariantes, análisis de componentes principales y análisis discriminante.

Autor: Luis López
Titulación: Grado en Estadística / Ciencia de Datos
Fecha: Abril 2026

Índice

Convenciones de notación **4**

1. Definición y tipos **4**

1.1. ¿Qué es el Análisis Multivariante? 4

1.2. Objetivos principales 5

1.3. Clasificación de las técnicas 5

1.3.1. Relación de dependencia entre variables 5

1.3.2. Interdependencia entre variables 6

1.3.3. Técnicas basadas en modelos no lineales 7

2. Pasos del análisis **7**

3. Formalización de los datos **7**

3.1. Variable univariante como vector 7

3.2. Variable vectorial y matriz de datos 8

4. Elementos de álgebra lineal **8**

4.1. Vectores 8

4.1.1. Relación entre producto escalar, normas y ángulo 9

4.1.2. Vector unitario y ortogonalidad 10

4.2. Matrices 10

4.2.1. Rango de una matriz 10

4.3. Operaciones con matrices 11

4.3.1. Suma de matrices 11

4.3.2. Multiplicación por un escalar 11

4.3.3. Multiplicación de matrices 11

4.4. Determinantes 12

4.5. Inversa de una matriz 12

4.6. Autovalores y autovectores 13

4.6.1. Autovalores (valores propios) 13

4.6.2. Autovectores (vectores propios) 14

4.6.3. Autovectores normalizados 14

4.7. Formas cuadráticas 15

4.7.1. Desarrollo explícito 16

4.7.2. Clasificación de formas cuadráticas 16

Tema 2: Distribuciones Multivariantes

1. Introducción **17**

2. Tipos de distribución **17**

2.1. Distribución conjunta 17

2.2. Distribuciones marginales 18

2.3. Distribuciones condicionadas 18

3. Independencia **18**

4. Medidas características **19**

4.1. Tendencia central: vector de medias 19

4.2. Variabilidad: matriz de varianzas y covarianzas 19

4.2.1. Matriz de datos centrados 20

4.2.2. S es semidefinida positiva 20

4.2.3. Variabilidad total 21

4.2.4. Varianza generalizada 21

4.2.5. Distancias 22

4.2.6. Distancia promedio 22

5. Medidas de dependencia lineal **23**

5.1. Dependencia entre pares: coeficiente de correlación 23

5.2. Dependencia entre una variable y el resto: regresión múltiple 24

5.3. Correlación parcial: eliminando el efecto de las demás 24

5.4. Dependencia global: determinante de **R** 25

5.5. Matriz de precisión 25

6. Transformaciones de vectores aleatorios **25**

6.1. Generalidades: función de densidad y cambio de variable 26

6.2. Esperanzas de transformaciones lineales 27

7. Modelos de distribuciones multivariantes **27**

7.1. Distribución multinomial 27

7.2. Distribución de Dirichlet 28

7.3. Distribución normal multivariante 28

Tema 3: Análisis de Componentes Principales

1. Introducción **30**

2. Planteamiento del problema **31**

2.1. Proyección y criterio de maximización 31

3. Cálculo de los componentes **32**

3.1. Cálculo del primer componente 32

3.2. Cálculo del segundo componente 33

3.3. Generalización 33

4. Propiedades de los componentes **34**

5. Análisis con correlaciones (análisis normado) **35**

6. Matriz de saturaciones o de cargas factoriales **36**

7. Resumen: cálculo de los componentes principales **36**

8. Interpretación de los componentes **37**

8.1. Interpretación geométrica 37

8.2. Interpretación sustantiva 38

9. Número de factores a extraer **38**

10. Rotaciones **38**

Tema 4: Análisis Discriminante

1. Introducción **40**

2. Caso de dos poblaciones **41**

2.1. Enfoque bayesiano general 41

2.1.1. Regla con costes de clasificación 41

2.2. Enfoque bayesiano en poblaciones normales 42

2.2.1. Probabilidad a posteriori en función de distancias 43

2.2.2. Estimación de parámetros en la práctica 43

2.2.3. Ejemplo numérico (dos pintores) 43

2.2.4. Probabilidad teórica de error (caso simétrico) 44

3. Generalización para varias poblaciones normales **44**

3.1. Fronteras de decisión 45

4. Función lineal de Fisher **45**
4.1. Caso de dos grupos 45
4.2. Caso de varios grupos 46

5. Variables canónicas discriminantes **46**

6. Evaluación del modelo: matriz de confusión **47**

7. Estudio de las dimensiones necesarias **47**

8. Algunas consideraciones prácticas **48**
8.1. Hipótesis de partida 48
8.2. Tamaño muestral 48

Formulario Final **50**

Convenciones de notación

Para mantener una exposición homogénea en todo el documento, utilizaremos las siguientes convenciones formales, que se respetarán en todos los temas:

- Los **escalares** se denotan en minúscula (x, λ, r), los **vectores** en negrita $(\mathbf{x}, \boldsymbol{\mu})$ y las **matrices** en negrita mayúscula $(\mathbf{X}, \mathbf{S}, \mathbf{R})$.
- $\mathbf{X} \in \mathbb{R}^{n \times p}$ representa una matriz de datos con n observaciones (filas) y p variables (columnas).
- El superíndice prima $(')$ indica trasposición; $\mathbf{A}^{-1}$ indica matriz inversa cuando existe.
- $\mathrm{tr}(\mathbf{A})$, $|\mathbf{A}|$ y $\mathrm{r}(\mathbf{A})$ denotan, respectivamente, traza, determinante y rango de $\mathbf{A}$.
- $E(\mathbf{X})$, $\mathrm{Var}(\mathbf{X})$ y $\mathrm{Cov}(\mathbf{X}, \mathbf{Y})$ representan esperanza, varianza y covarianza.
- En contextos muestrales, se usará barra superior para medias $(\bar{\mathbf{x}})$ y letras con sombrero para estimadores $(\hat{\boldsymbol{\Sigma}}, \hat{\pi}_g)$.

1. Definición y tipos

1.1. ¿Qué es el Análisis Multivariante?

Definición 1.1 (Análisis Multivariante)**.** El análisis multivariante es el conjunto de métodos estadísticos diseñados para estudiar **simultáneamente** varias variables observadas sobre una misma unidad experimental u observacional, preservando su estructura conjunta de dependencia.

En gran parte de las técnicas multivariantes, el objeto algebraico central es una combinación lineal de variables observadas, cuyas ponderaciones se ajustan según el objetivo inferencial (síntesis, discriminación, predicción o descripción estructural). En

este documento la denominaremos **valor teórico**.

$$\text{Valor teórico} = w_1X_1 + w_2X_2 + \cdots + w_pX_p$$

Definición de variables (primera aparición). En esta expresión, X_i es valor observado de la variable i ; w_i es peso asignado a la variable i por la técnica multivariante ; p es número de variables incluidas en la combinación .

El resultado es una variable escalar sintética que resume, en una dirección determinada del espacio de variables, la información más relevante para el problema estadístico planteado.

1.2. Objetivos principales

Desde una perspectiva aplicada, el análisis multivariante persigue cuatro metas complementarias:

1. **Resumir** el conjunto original en pocas variables derivadas, minimizando la pérdida de información relevante. (*ej.: componentes principales, análisis factorial*).
2. **Detectar grupos** naturales en los datos, cuando existan. (*ej.: tipología de procesos productivos, de clientes, de partículas*).
3. **Clasificar** nuevas observaciones en grupos previamente definidos. (*ej.: clientes de un banco como fiables o no, personas como enfermas o no, partículas subatómicas como fermión o bosón*).
4. **Relacionar** dos bloques de variables para estudiar estructura común y dependencia cruzada. (*ej.: un conjunto de variables de capacidad intelectual y otro de resultados profesionales*).

1.3. Clasificación de las técnicas

Existen diversas taxonomías. Seguimos la propuesta de **Hair, Tathan y Black (1998)**, que organiza las técnicas según el *tipo de relación entre variables* y distingue entre modelos de dependencia, interdependencia y estructura no lineal.

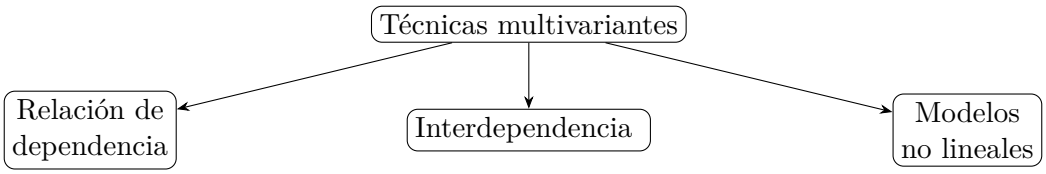

Figura 1: *Esquema general de clasificación (Hair et al., 1998).*

1.3.1. Relación de dependencia entre variables

En este bloque se distingue explícitamente una variable respuesta (o un bloque de respuestas) y un conjunto de variables explicativas. El objetivo es modelar la distribución o el valor esperado de la respuesta condicionado a los predictores.

Una variable dependiente.

Regresión múltiple: variación de una variable dependiente cuantitativa a partir de la variación de dos o más variables independientes.

- **Análisis discriminante:** variable dependiente dicotómica o politómica; divide la muestra total en grupos basándose en una variable dependiente con clases conocidas. Sus objetivos son:
  - Entender las diferencias entre grupos.
  - Predecir la verosimilitud de que una entidad pertenezca a una clase o grupo particular, basándose en varias variables cuantitativas independientes.
- **Regresión logística:** variable dependiente dicotómica con variables independientes cuantitativas.
- **Modelos logit:** variable dependiente dicotómica con variables independientes cuantitativas *y* cualitativas.

Varias variables dependientes.

- Con variables independientes cuantitativas:
  Análisis de correlación canónica: extensión de la regresión múltiple al caso de múltiples variables dependientes. Obtiene un conjunto de ponderaciones para las variables dependientes e independientes que proporciona la correlación máxima entre el conjunto de variables dependientes y el de independientes.
- Con variables independientes cualitativas:
  - **Análisis de varianza multivariante (MANOVA).**
  - **Análisis de correspondencias.**

Modelos de ecuaciones estructurales.

1.3.2. Interdependencia entre variables

En interdependencia no se fija a priori la dicotomía respuesta–explicativa; el interés se desplaza a la geometría y estructura interna del conjunto de variables.

Análisis de componentes principales (ACP): analiza las interrelaciones entre un gran número de variables y las explica en términos de sus dimensiones subyacentes comunes (*factores*). Permite condensar la información de las variables originales en un conjunto más pequeño de variables con una pérdida mínima de información.

Análisis de conglomerados (cluster): agrupa observaciones similares para descubrir la estructura de grupos en los datos.

Con variables cuantitativas: **Escalado multidimensional**, que transforma similitudes o disimilitudes de un conjunto de objetos en distancias representadas en un espacio multidimensional.

1.3.3. Técnicas basadas en modelos no lineales

- **Método de superficie de respuesta:** estudio de las relaciones de dependencia entre las variables.
- **Análisis factorial no lineal:** relaciones de interdependencia.

2. Pasos del análisis

Un flujo de trabajo multivariante riguroso puede organizarse en las diez etapas siguientes:

1. **Definición del problema de investigación** y objetivos del análisis.
2. **Definición de las variables**, su tipo (cuantitativa o cualitativa) y tipo de relación que se establece entre ellas.
3. **Selección de la técnica multivariante** en función del objetivo y de las variables estudiadas.
4. **Determinación del tamaño muestral** y elementos necesarios para la recogida de datos.
5. **Recogida de datos.**
6. **Análisis previo de los datos**: detección de valores atípicos, datos perdidos, normalidad univariante.
7. **Evaluación de los supuestos** de la técnica multivariante (normalidad multivariante, homocedasticidad, linealidad, etc.).
8. **Estimación de los parámetros del modelo.**
9. **Evaluación del ajuste del modelo.**
10. **Interpretación de los resultados.**

Observación. Las etapas 6 y 7 son críticas: los métodos multivariantes son muy sensibles a la presencia de outliers y al incumplimiento de los supuestos distribucionales. Un análisis exploratorio previo riguroso ahorra errores de interpretación.

3. Formalización de los datos

3.1. Variable univariante como vector

Si disponemos de n observaciones numéricas de una variable escalar X, cada dato puede identificarse con la componente i-ésima de un **vector columna** en $\mathbb{R}^n$:

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \in \mathbb{R}^n.$$

Ejemplo 3.1. Edades de 3 personas:

$$\mathbf{x} = \begin{pmatrix} 18 \\ 21 \\ 34 \end{pmatrix}.$$

3.2. Variable vectorial y matriz de datos

Cuando se miden p variables sobre cada una de las n unidades observacionales, los datos se organizan naturalmente en una tabla de n filas y p columnas. Cada columna recoge una variable y cada fila el perfil multivariante completo de una unidad.

Definición 3.1 (Matriz de datos)**.** Los valores de las p variables escalares en cada uno de los n elementos se representan en la **matriz de datos X** de dimensión $n \times p$:

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}, \qquad \begin{array}{ll} i = 1, \ldots, n & \text{(individuo)} \\ j = 1, \ldots, p & \text{(variable)} \end{array}$$

Definición de variables (primera aparición). En esta expresión, n es número de individuos u observaciones ; x_{ij} es valor de la variable j en el individuo i ; $\mathbf{X}_{(j)}$ es columna j de la matriz de datos .

También se escribe $\mathbf{X} = [\mathbf{X}_{(1)}, \ldots, \mathbf{X}_{(p)}] = [\mathbf{x}_{ij}]$, donde $\mathbf{X}_{(j)}$ es la columna asociada a la variable j y la fila i contiene el perfil multivariante de la observación i. Esta convención (filas = individuos, columnas = variables) se mantendrá en todo el documento porque permite expresar con claridad medias, centrado, covarianzas y proyecciones lineales.

4. Elementos de álgebra lineal

4.1. Vectores

Definición 4.1 (Vector traspuesto)**.** El vector traspuesto de $\mathbf{x}$, denotado $\mathbf{x}'$, es el vector $\mathbf{x}$ con los mismos componentes dispuestos en fila:

$$\mathbf{x}' = (x_1, x_2, \ldots, x_n).$$

Definición 4.2 (Producto escalar o interno)**.** El producto escalar de dos vectores $\mathbf{x}$ e $\mathbf{y}$ de igual dimensión es el número:

$$\mathbf{x}'\mathbf{y} = \sum_{i=1}^{n} x_i y_i.$$

En particular,

$$\mathbf{x}'\mathbf{x} = \sum_{i=1}^{n} x_i^2 \geq 0,$$

con igualdad si y solo si $\mathbf{x} = \mathbf{0}$.

Observación. En análisis multivariante, el producto escalar fija la noción geométrica de longitud, ángulo y proyección, y por tanto está en la base de distancias, ortogonalidad y cambios de base.

Definición 4.3 (Norma de un vector)**.** La **norma** o longitud de un vector $\mathbf{x}$ es la raíz cuadrada de su producto escalar consigo mismo:

$$\|\mathbf{x}\| = \sqrt{\mathbf{x}'\mathbf{x}} = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2}.$$

Geométricamente, es la longitud del segmento que une el origen con el punto $\mathbf{x}$.

4.1.1. Relación entre producto escalar, normas y ángulo

El producto escalar de dos vectores puede calcularse como el producto de sus normas por el coseno del ángulo que forman:

$$\boxed{\mathbf{x}'\mathbf{y} = \|\mathbf{x}\|\,\|\mathbf{y}\|\,\cos\theta.}$$

Proposición 4.4 (Desigualdad de Cauchy–Schwarz)**.** *Para cualesquiera* $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$ *se cumple:*

$$|\mathbf{x}'\mathbf{y}| \leq \|\mathbf{x}\|\,\|\mathbf{y}\|.$$

La igualdad se alcanza si y solo si $\mathbf{x}$ *y* $\mathbf{y}$ *son linealmente dependientes.*

Demostración. Para $t \in \mathbb{R}$*, la cantidad* $\|\mathbf{x} - t\mathbf{y}\|^2 = (\mathbf{x} - t\mathbf{y})'(\mathbf{x} - t\mathbf{y})$ *es no negativa. Al desarrollar:*

$$\|\mathbf{x}\|^2 - 2t\,\mathbf{x}'\mathbf{y} + t^2\|\mathbf{y}\|^2 \geq 0.$$

Este polinomio cuadrático en t *debe tener discriminante no positivo, luego*

$$4(\mathbf{x}'\mathbf{y})^2 - 4\|\mathbf{x}\|^2\|\mathbf{y}\|^2 \leq 0 \quad \Longrightarrow \quad |\mathbf{x}'\mathbf{y}| \leq \|\mathbf{x}\|\,\|\mathbf{y}\|.$$

La igualdad equivale a discriminante nulo, que ocurre exactamente cuando existe t *tal que* $\mathbf{x} = t\mathbf{y}$. □

Ejemplo 4.1. Para $\mathbf{x} = \begin{pmatrix} a \\ 0 \end{pmatrix}$ e $\mathbf{y} = \begin{pmatrix} a \\ c \end{pmatrix}$:

$$\|\mathbf{x}\| = a, \quad \|\mathbf{y}\| = \sqrt{a^2 + c^2}, \quad \cos\theta = \frac{a}{\sqrt{a^2 + c^2}},$$

$$\mathbf{x}'\mathbf{y} = a \cdot \sqrt{a^2 + c^2} \cdot \frac{a}{\sqrt{a^2 + c^2}} = a^2.$$

Observación. El producto escalar puede interpretarse como el producto de la norma de un vector por la *proyección* del otro sobre él.

4.1.2. Vector unitario y ortogonalidad

Definición 4.5 (Vector unitario o normalizado)**.** Un vector es **unitario** si su norma es 1:

$$\mathbf{u} = \frac{\mathbf{x}}{\|\mathbf{x}\|}, \qquad \mathbf{u}'\mathbf{u} = 1.$$

Definición 4.6 (Ortogonalidad)**.** Dos vectores son **ortogonales** si su producto escalar es nulo:

$$\mathbf{x}'\mathbf{y} = \|\mathbf{x}\|\,\|\mathbf{y}\|\,\cos\theta = 0 \quad \Longleftrightarrow \quad \theta = 90^\circ.$$

Definición 4.7 (Ortonormalidad)**.** Dos vectores son **ortonormales** si son ortogonales *y* ambos tienen norma 1 (normalizados).

4.2. Matrices

Definición 4.8 (Tipos básicos de matrices)**.** En esta materia aparecen de forma recurrente varios tipos de matrices:

- **Cuadrada de orden** p: dimensión $p \times p$ (si $n \neq p$, la matriz es rectangular).
- **Traspuesta**: para $\mathbf{A} \in \mathbb{R}^{n\times p}$, $\mathbf{A}' \in \mathbb{R}^{p\times n}$ se obtiene intercambiando filas y columnas.
- **Traza**: $\mathrm{tr}(\mathbf{A}) = \sum_i a_{ii}$, con $\mathrm{tr}(\mathbf{A}) = \mathrm{tr}(\mathbf{A}')$.
- **Simétrica**: $\mathbf{A} = \mathbf{A}'$.
- **Nula**: todos sus elementos son cero.
- **Diagonal**: elementos no diagonales nulos.
- **Escalar**: diagonal con todos los valores diagonales iguales.
- **Identidad**: diagonal con unos en la diagonal principal.

4.2.1. Rango de una matriz

Definición 4.9 (Rango)**.** El **rango** de una matriz $\mathbf{A}$, denotado $\mathrm{r}(\mathbf{A})$, es el máximo número de columnas (equivalentemente, filas) linealmente independientes de $\mathbf{A}$.

Las propiedades de rango más usadas en estos apuntes son:

$$0 \leq \mathrm{r}(\mathbf{A}) \leq \text{mín}(n, p). \tag{1}$$

$$\text{Si } \mathbf{A} \text{ es cuadrada: } \mathrm{r}(\mathbf{A}) \leq p. \tag{2}$$

$$\text{Si } \mathbf{A} \text{ es regular de orden } p : \mathrm{r}(\mathbf{A}) = p. \tag{3}$$

$$\text{Si } \mathbf{A} \text{ es singular de orden } p : \mathrm{r}(\mathbf{A}) < p. \tag{4}$$

$$\mathrm{r}(\mathbf{A}) = \mathrm{r}(\mathbf{A}'). \tag{5}$$

$$\mathrm{r}(\mathbf{A}'\mathbf{A}) = \mathrm{r}(\mathbf{A}\mathbf{A}') = \mathrm{r}(\mathbf{A}) = \mathrm{r}(\mathbf{A}'). \tag{6}$$

Observación. El rango cuantifica la dimensión efectiva del subespacio generado por las variables. En términos estadísticos, detectar rango deficiente equivale a detectar redundancia lineal.

Proposición 4.10 (Carácter de invertibilidad en matrices cuadradas)**.** *Sea* $\mathbf{A} \in \mathbb{R}^{p\times p}$*. Son equivalentes:*

1. $\mathbf{A}$ *es invertible;*
2. $|\mathbf{A}| \neq 0$*;*
3. $\mathrm{r}(\mathbf{A}) = p$*;*
4. *el sistema homogéneo* $\mathbf{Ax} = \mathbf{0}$ *solo tiene la solución trivial.*

> *Demostración. La equivalencia* (1) $\Leftrightarrow$ (2) *es el criterio clásico del determinante. La equivalencia* (2) $\Leftrightarrow$ (3) *se sigue de que, para matrices cuadradas, tener determinante no nulo equivale a tener rango máximo. Finalmente,* (3) $\Leftrightarrow$ (4) *expresa que la nulidad es cero (*teorema rango–nulidad*), por lo que el núcleo contiene solo* $\mathbf{0}$*.* □

Observación. El rango indica la *dimensión real* necesaria para representar el conjunto de datos (número real de variables aleatorias de que disponemos). Analizar el rango de una matriz de datos es clave para reducir el número de variables sin pérdida de información.

4.3. Operaciones con matrices

4.3.1. Suma de matrices

Para sumar dos matrices es necesario que tengan el **mismo orden**:

$$\mathbf{A} + \mathbf{B} = [a_{ij} + b_{ij}], \quad i = 1, \ldots, n,\ j = 1, \ldots, p.$$

Propiedades adicionales a la conmutativa y asociativa:

$$(\mathbf{A} + \mathbf{B})' = \mathbf{A}' + \mathbf{B}', \qquad \mathrm{tr}(\mathbf{A} + \mathbf{B}) = \mathrm{tr}(\mathbf{A}) + \mathrm{tr}(\mathbf{B}).$$

4.3.2. Multiplicación por un escalar

$$k\mathbf{A} = \mathbf{A}k = [k\, a_{ij}].$$

4.3.3. Multiplicación de matrices

Para multiplicar $\mathbf{A}$ y $\mathbf{B}$, el número de columnas de $\mathbf{A}$ debe coincidir con el número de filas de $\mathbf{B}$:

$$\boxed{\mathbf{A}_{n\times p} \times \mathbf{B}_{p\times m} = \mathbf{C}_{n\times m}, \quad c_{ij} = \sum_{k=1}^{p} a_{ik}\, b_{kj}.}$$

Ejemplo 4.2.

$$\begin{pmatrix} 4 & 2 & 3 \\ 5 & 1 & 2 \end{pmatrix} \times \begin{pmatrix} 2 & 3 \\ 1 & 5 \\ 4 & 2 \end{pmatrix} = \begin{pmatrix} 22 & 28 \\ 19 & 24 \end{pmatrix}.$$

Propiedades de la multiplicación de matrices.

- $\mathbf{A}(\mathbf{BC}) = (\mathbf{AB})\mathbf{C}$ —asociativa—
- $\mathbf{AB} \neq \mathbf{BA}$ —no conmutativa en general—
- $\mathbf{AI} = \mathbf{IA} = \mathbf{A}$
- $\mathbf{A}^2 = \mathbf{AA}$ (si $\mathbf{A}$ es cuadrada)
- $\mathrm{tr}(\mathbf{AB}) = \mathrm{tr}(\mathbf{BA})$ (si $\mathbf{A}$ es cuadrada)
- $|\mathbf{AB}| = |\mathbf{A}|\,|\mathbf{B}|$ (si $\mathbf{A}$ y $\mathbf{B}$ son cuadradas del mismo orden)
- $(\mathbf{ABC})' = \mathbf{C}'\mathbf{B}'\mathbf{A}'$

4.4. Determinantes

Definición 4.11 (Determinante)**.** El determinante $|\mathbf{A}|$ es un **polinomio** de los elementos de la matriz $\mathbf{A}$, es decir, un valor escalar calculado a partir de una matriz cuadrada.

Observación. En multivariante, el determinante de una matriz de covarianzas mide volumen generalizado y aparece de forma natural en densidades gaussianas y en criterios de dependencia global.

Ejemplo 4.3.

$$\mathbf{A} = \begin{pmatrix} 3 & 2 \\ 1 & 4 \end{pmatrix} \Rightarrow |\mathbf{A}| = 3 \cdot 4 - 2 \cdot 1 = 10.$$

$$\mathbf{B} = \begin{pmatrix} 4 & 1 & 2 \\ 2 & 5 & 1 \\ 3 & 6 & 2 \end{pmatrix} \Rightarrow |\mathbf{B}| = 9 \quad \text{(desarrollo por cofactores).}$$

- Si $|\mathbf{A}| = 0$: la matriz es **singular** (no invertible, dependencia lineal entre filas/columnas).
- Si $|\mathbf{A}| \neq 0$: la matriz es **regular** (invertible, filas y columnas linealmente independientes).

4.5. Inversa de una matriz

Definición 4.12 (Matriz inversa)**.** La inversa de una matriz $\mathbf{A}$ es la matriz $\mathbf{A}^{-1}$ tal que

$$\mathbf{AA}^{-1} = \mathbf{A}^{-1}\mathbf{A} = \mathbf{I}.$$

Solo existe para matrices **cuadradas y regulares**.

Se calcula mediante la **matriz adjunta**:

$$\mathbf{A}^{-1} = \frac{1}{|\mathbf{A}|}\,\mathbf{A}^{\wedge},$$

donde $\mathbf{A}^{\Lambda}$ es la adjunta de $\mathbf{A}'$: matriz de adjuntos $A_{ij} = (-1)^{i+j}|\mathbf{A}_{ij}|$, siendo $\mathbf{A}_{ij}$ la submatriz de orden $n-1$ obtenida eliminando la fila i y la columna j de $\mathbf{A}'$.

Observación. La inversa de la covarianza (matriz de precisión) codifica dependencias condicionales lineales y tiene papel central en inferencia gaussiana y discriminación lineal.

Ejemplo 4.4. Para $\mathbf{A} = \begin{pmatrix} 3 & 2 \\ 1 & 4 \end{pmatrix}$, $|\mathbf{A}| = 10$:

$$\mathbf{A}^{-1} = \frac{1}{10}\begin{pmatrix} 4 & -2 \\ -1 & 3 \end{pmatrix} = \begin{pmatrix} 0{,}4 & -0{,}2 \\ -0{,}1 & 0{,}3 \end{pmatrix}.$$

Ejemplo 4.5. Para $\mathbf{B} = \begin{pmatrix} 4 & 1 & 2 \\ 2 & 5 & 1 \\ 3 & 6 & 2 \end{pmatrix}$, $|\mathbf{B}| = 9$:

$$\mathbf{B}^{-1} = \frac{1}{9}\begin{pmatrix} 4 & 10 & -9 \\ -1 & 2 & 0 \\ -3 & -21 & 18 \end{pmatrix} \approx \begin{pmatrix} 0{,}44 & 1{,}11 & -1 \\ -0{,}11 & 0{,}22 & 0 \\ -0{,}33 & -2{,}33 & 2 \end{pmatrix}.$$

4.6. Autovalores y autovectores

4.6.1. Autovalores (valores propios)

Definición 4.13 (Autovalor)**.** Sea $\mathbf{A}$ una matriz cuadrada de orden p. Un escalar λ es un **autovalor** (valor propio o raíz latente) de $\mathbf{A}$ si:

$$|\mathbf{A} - \lambda\mathbf{I}| = 0.$$

Esta es la **ecuación característica**: un polinomio de grado p cuyas raíces (con multiplicidad algebraica) son los autovalores de $\mathbf{A}$.

Observación. La lectura conceptual es: la matriz define una transformación lineal y los autovalores cuantifican los factores de escala en direcciones invariantes autovectoriales.

Ejemplo 4.6. Calcular los autovalores de $\mathbf{A} = \begin{pmatrix} 1 & 4 \\ 9 & 1 \end{pmatrix}$:

$$|\mathbf{A} - \lambda\mathbf{I}| = 0 \quad \Longrightarrow \quad \begin{vmatrix} 1-\lambda & 4 \\ 9 & 1-\lambda \end{vmatrix} = 0 \tag{7}$$

$$(1-\lambda)^2 - 36 = 0 \quad \Longrightarrow \quad \lambda^2 - 2\lambda - 35 = 0 \tag{8}$$

$$\lambda = \frac{2 \pm \sqrt{4+140}}{2} \quad \Longrightarrow \quad \lambda_1 = 7, \quad \lambda_2 = -5. \tag{9}$$

Propiedades de los autovalores.

- $\sum_i \lambda_i = \mathrm{tr}(\mathbf{A})$.
- $\prod_i \lambda_i = |\mathbf{A}|$.
- Si $|\mathbf{A}| = 0$, al menos un $\lambda_i = 0$.
- $\mathrm{r}(\mathbf{A})$ es el número de λ_i distintos de 0.
- En una matriz diagonal, los autovalores son los elementos de la diagonal principal.

Estas identidades conectan directamente álgebra lineal y estadística multivariante: por ejemplo, en ACP los autovalores de $\mathbf{S}$ miden varianza explicada.

4.6.2. Autovectores (vectores propios)

Definición 4.14 (Autovector)**.** Sea $\mathbf{A}$ cuadrada, λ un autovalor y $\mathbf{x} \neq \mathbf{0}$ tal que:

$$\mathbf{A}\mathbf{x} = \lambda\mathbf{x}.$$

$\mathbf{x}$ es un **autovector** (vector propio, característico o latente) de $\mathbf{A}$ asociado a λ.

La ecuación $\mathbf{A}\mathbf{x} = \lambda\mathbf{x}$ equivale al sistema homogéneo $(\mathbf{A} - \lambda\mathbf{I})\mathbf{x} = \mathbf{0}$. Por tanto, para un λ dado existe autovector no nulo si y solo si $|\mathbf{A} - \lambda\mathbf{I}| = 0$.

En general, la multiplicidad geométrica puede ser menor que la algebraica. En el caso simétrico real, el teorema espectral garantiza una base ortonormal completa de autovectores.

Ejemplo 4.7. Para $\mathbf{A} = \begin{pmatrix} 1 & 4 \\ 9 & 1 \end{pmatrix}$ con $\lambda_1 = 7$, $\lambda_2 = -5$:

Autovector asociado a $\lambda_1 = 7$:

$$(\mathbf{A} - 7\mathbf{I})\mathbf{x}_1 = \mathbf{0} \quad \Longrightarrow \quad \begin{pmatrix} -6 & 4 \\ 9 & -6 \end{pmatrix} \begin{pmatrix} x_{11} \\ x_{21} \end{pmatrix} = \mathbf{0} \quad \Longrightarrow \quad \mathbf{x}_1 = \begin{pmatrix} 2 \\ 3 \end{pmatrix}.$$

Autovector asociado a $\lambda_2 = -5$:

$$(\mathbf{A} + 5\mathbf{I})\mathbf{x}_2 = \mathbf{0} \quad \Longrightarrow \quad \begin{pmatrix} 6 & 4 \\ 9 & 6 \end{pmatrix} \begin{pmatrix} x_{12} \\ x_{22} \end{pmatrix} = \mathbf{0} \quad \Longrightarrow \quad \mathbf{x}_2 = \begin{pmatrix} 2 \\ -3 \end{pmatrix}.$$

4.6.3. Autovectores normalizados

Definición 4.15 (Autovector normalizado)**.**

$$\mathbf{u}_i = \frac{\mathbf{x}_i}{\|\mathbf{x}_i\|}.$$

Ejemplo 4.8. Tomando los autovectores del ejemplo anterior $\mathbf{x}_1 = \begin{pmatrix} 2 \\ 3 \end{pmatrix}$ y $\mathbf{x}_2 = \begin{pmatrix} 2 \\ -3 \end{pmatrix}$,

se tiene:

$$\|\mathbf{x}_1\| = \sqrt{2^2+3^2} = \sqrt{13}, \qquad \|\mathbf{x}_2\| = \sqrt{2^2+(-3)^2} = \sqrt{13}.$$

$$\mathbf{u}_1 = \frac{\mathbf{x}_1}{\|\mathbf{x}_1\|} = \begin{pmatrix} 2/\sqrt{13} \\ 3/\sqrt{13} \end{pmatrix} \approx \begin{pmatrix} 0{,}55 \\ 0{,}83 \end{pmatrix}, \tag{10}$$

$$\mathbf{u}_2 = \frac{\mathbf{x}_2}{\|\mathbf{x}_2\|} = \begin{pmatrix} 2/\sqrt{13} \\ -3/\sqrt{13} \end{pmatrix} \approx \begin{pmatrix} 0{,}55 \\ -0{,}83 \end{pmatrix}. \tag{11}$$

Por tanto, la **matriz de autovectores normalizados** queda:

$$\mathbf{U} = \begin{pmatrix} 0{,}55 & 0{,}55 \\ 0{,}83 & -0{,}83 \end{pmatrix}.$$

Propiedades de los autovectores.

- Si $\mathbf{A}$ es simétrica, sus autovectores son **ortogonales**.
- Dada $\mathbf{A}$ simétrica, siendo $\mathbf{\Lambda}$ la matriz diagonal que contiene los autovalores y $\mathbf{U}$ la matriz de autovectores normalizados:

$$\mathbf{A} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}' \quad \Longrightarrow \quad \mathbf{A}^{-1} = \mathbf{U}\mathbf{\Lambda}^{-1}\mathbf{U}'.$$

$$\mathbf{\Lambda} = \mathbf{U}'\mathbf{A}\mathbf{U}.$$

- Al aplicar una matriz cuadrada de orden n a un vector de dimensión n, en general se transforma en dirección y magnitud.
- Los autovectores son aquellos vectores que, al ser transformados por la matriz, solo modifican su longitud (norma), no su posición en el espacio.

4.7. Formas cuadráticas

Definición 4.16 (Forma cuadrática)**.** Las formas cuadráticas aparecen de forma sistemática en multivariante: distancia de Mahalanobis, densidades gaussianas, criterios de optimización de ACP y análisis discriminante.

Si transformamos un vector $\mathbf{x}$ mediante una transformación lineal $\mathbf{y} = \mathbf{B}\mathbf{x}$, la norma al cuadrado del nuevo vector es:

$$\mathbf{y}'\mathbf{y} = \mathbf{x}'\mathbf{B}'\mathbf{B}\mathbf{x} = \mathbf{x}'\mathbf{A}\mathbf{x},$$

donde $\mathbf{A} = \mathbf{B}'\mathbf{B}$ es cuadrada y simétrica.

La expresión $Q = \mathbf{x}'\mathbf{A}\mathbf{x}$ se denomina **forma cuadrática** asociada a $\mathbf{A}$. Si $\mathbf{A}$ es simétrica, su signo queda completamente determinado por el signo de sus autovalores.

4.7.1. Desarrollo explícito

Para $\mathbf{A}_{2\times 2}$:

$$Q = \mathbf{x}'\mathbf{A}\mathbf{x} = \begin{pmatrix} x_1 & x_2 \end{pmatrix} \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = a_{11}x_1^2 + (a_{12} + a_{21})x_1x_2 + a_{22}x_2^2.$$

En general, para $\mathbf{A}_{p\times p}$:

$$\boxed{Q = \mathbf{x}'\mathbf{A}\mathbf{x} = \sum_i a_{ii}x_i^2 + \sum_{i<j}(a_{ij} + a_{ji})x_ix_j.}$$

4.7.2. Clasificación de formas cuadráticas

- Para $\mathbf{x} = \mathbf{0}$: $Q = 0$ siempre.
- **Definida positiva:** $Q > 0$ para todo $\mathbf{x} \neq \mathbf{0}$. Equivale a: $\mathbf{A}$ regular, $\mathrm{r}(\mathbf{A}) = p$ y todos los autovalores son positivos.
- **Semidefinida positiva:** $Q \geq 0$ para todo $\mathbf{x} \neq \mathbf{0}$. Equivale a: $\mathbf{A}$ singular, $\mathrm{r}(\mathbf{A}) < p$ y autovalores positivos con al menos uno nulo.

Observación. La clasificación positiva/semidefinida no es solo algebraica: determina si una distancia o una varianza generalizada están bien definidas y no negativas.

Ejemplo 4.9. $\mathbf{A} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$, $Q = \mathbf{x}'\mathbf{A}\mathbf{x} = x_1^2 + x_2^2 > 0$, $|\mathbf{A}| = 1$, $\mathrm{r}(\mathbf{A}) = 2 = p$, $\lambda_1 = \lambda_2 = 1 > 0 \Rightarrow$ **definida positiva**.

Ejemplo 4.10. $\mathbf{B} = \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}$, $Q = x_1^2 + x_2^2 - 2x_1x_2 = (x_1 - x_2)^2 \geq 0$, $|\mathbf{B}| = 0$, $\mathrm{r}(\mathbf{B}) = 1 < p$, $\lambda_1 = 0$, $\lambda_2 = 2 \Rightarrow$ **semidefinida positiva**.

Tema 2

Distribuciones Multivariantes

1. Introducción

El **problema central del análisis de datos** es decidir si las propiedades encontradas en una muestra pueden generalizarse a la población de la que provienen. Para ello es necesario disponer de un *modelo del sistema generador de los datos*: suponer una distribución de probabilidad para la variable aleatoria en la población.

En consecuencia, el primer paso del tema es definir con precisión distribución conjunta, marginal y condicionada, y después estudiar cómo se traducen esas estructuras en medidas de dependencia y en modelos paramétricos.

Definición 1.1 (Variable aleatoria multidimensional o vectorial)**.** Una variable aleatoria multidimensional es el resultado de observar p características en un elemento de la población. Puede ser:

- **Discreta:** cuando lo es cada una de las p variables escalares que la componen.
- **Continua:** cuando lo es cada una de las p variables escalares que la componen.
- **Mixta:** cuando algunos componentes son discretos y otros continuos.

2. Tipos de distribución

2.1. Distribución conjunta

Definición 2.1 (Función de distribución conjunta)**.** La distribución de probabilidad que describe simultáneamente el comportamiento del vector aleatorio $\mathbf{X} = (X_1, \ldots, X_p)'$ es la **distribución conjunta**. Dado $\mathbf{x}^0 = (x_1^0, \ldots, x_p^0)'$, su función de distribución conjunta se define como:

$$\boxed{F_{\mathbf{X}}(\mathbf{x}^0) = P(\mathbf{X} \leq \mathbf{x}^0) = P(X_1 \leq x_1^0, \ldots, X_p \leq x_p^0).}$$

$P(\mathbf{X} \leq \mathbf{x}^0)$ es la probabilidad de que la variable tome valores menores o iguales al valor particular $\mathbf{x}^0$. La función de distribución acumula las probabilidades de todos los valores menores o iguales al punto considerado, y será no decreciente.

Definición de variables (primera aparición). En esta expresión, $\mathbf{X}$ es vector aleatorio de dimensión p ; $\mathbf{x}^0$ es valor concreto del vector en el que se evalúa la distribución ; $F_{\mathbf{X}}(\mathbf{x}^0)$ es función de distribución conjunta acumulada ; $P(\cdot)$ es probabilidad del evento indicado .

Habitualmente se trabaja con:

- **Variable discreta:** función de probabilidad $p_{\mathbf{X}}(\mathbf{x}^0) = P(\mathbf{X} = \mathbf{x}^0) = P(X_1 = x_1^0, \ldots, X_p = x_p^0)$.
- **Variable continua:** el vector $\mathbf{X}$ es absolutamente continuo si existe una función de densidad $f_{\mathbf{X}}(\mathbf{x})$ tal que

$$F_{\mathbf{X}}(\mathbf{x}^0) = \int_{(-\infty,\mathbf{x}^0]} f_{\mathbf{X}}(\mathbf{x})\, d\mathbf{x}, \qquad d\mathbf{x} = dx_1 \cdots dx_p.$$

2.2. Distribuciones marginales

Definición 2.2 (Distribución marginal)**.** Dada una variable aleatoria vectorial p-dimensional $\mathbf{X} = (X_1, \ldots, X_p)'$, llamamos **distribución marginal** de cada componente a la distribución univariante de dicho componente, sin tener en cuenta los otros. Para $p = 2$:

$$f_{X_1}(x_1) = \int_{-\infty}^{+\infty} f_{X_1,X_2}(x_1, x_2)\, dx_2, \qquad f_{X_2}(x_2) = \int_{-\infty}^{+\infty} f_{X_1,X_2}(x_1, x_2)\, dx_1.$$

Las marginales describen el comportamiento de cada componente por separado; la conjunta añade, además, la estructura de dependencia entre componentes.

2.3. Distribuciones condicionadas

Definición 2.3 (Distribución condicionada)**.** Si $\mathbf{X}_1$ y $\mathbf{X}_2$ son subvectores de $\mathbf{X}$, la **distribución condicionada** de $\mathbf{X}_1$ dado $\mathbf{X}_2 = \mathbf{x}_2^0$ se define como:

$$f_{\mathbf{X}_1|\mathbf{X}_2}(\mathbf{x}_1 \mid \mathbf{x}_2^0) = \frac{f_{\mathbf{X}_1,\mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2^0)}{f_{\mathbf{X}_2}(\mathbf{x}_2^0)}, \qquad \text{si } f_{\mathbf{X}_2}(\mathbf{x}_2^0) \neq 0.$$

Definición de variables (primera aparición). En esta expresión, $\mathbf{X}_1$ es subvector aleatorio de interés ; $\mathbf{X}_2$ es subvector aleatorio sobre el que se condiciona ; $\mathbf{x}_2^0$ es valor fijado del subvector $\mathbf{x}_2$; $f_{\mathbf{X}_1|\mathbf{X}_2}(\mathbf{x}_1 \mid \mathbf{x}_2^0)$ es densidad condicionada .

3. Independencia

Definición 3.1 (Independencia)**.** Dos vectores aleatorios $\mathbf{X}_1$, $\mathbf{X}_2$ son **independientes** si el conocimiento de uno no aporta información respecto a los valores del otro:

$$f_{\mathbf{X}_2|\mathbf{X}_1}(\mathbf{x}_2 \mid \mathbf{x}_1) = \frac{f_{\mathbf{X}_1,\mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2)}{f_{\mathbf{X}_1}(\mathbf{x}_1)} = f_{\mathbf{X}_2}(\mathbf{x}_2),$$

es decir, si $f_{\mathbf{X}_1,\mathbf{X}_2}(\mathbf{x}_1, \mathbf{x}_2) = f_{\mathbf{X}_1}(\mathbf{x}_1) f_{\mathbf{X}_2}(\mathbf{x}_2)$.

En general, las variables $\mathbf{X}_1, \ldots, \mathbf{X}_p$ son independientes si:

$$f_{\mathbf{X}_1,\ldots,\mathbf{X}_p}(\mathbf{x}_1, \ldots, \mathbf{x}_p) = \prod_{j=1}^{p} f_{\mathbf{X}_j}(\mathbf{x}_j).$$

La independencia conjunta es una condición muy fuerte: cualquier subconjunto de variables mantiene la independencia. Además, al aplicar funciones adecuadas componente a componente, las variables transformadas siguen siendo independientes.

Observación. Cuando las variables son independientes, no ganamos nada con su estudio conjunto, y conviene estudiarlas individualmente.

4. Medidas características

4.1. Tendencia central: vector de medias

Definición 4.1 (Vector de medias)**.** La **esperanza** o **vector de medias** $\boldsymbol{\mu}$ de una variable multidimensional $\mathbf{X}$ es el vector cuyas componentes son las esperanzas de las componentes:

$$\boldsymbol{\mu} = E(\mathbf{X}), \qquad \bar{\mathbf{x}} = \frac{1}{n}\sum_{i=1}^{n} \mathbf{x}_i, \qquad \boldsymbol{\mu} = \int_{\mathbb{R}^p} \mathbf{x}\, f_{\mathbf{X}}(\mathbf{x})\, d\mathbf{x}.$$

En notación matricial (con $\mathbf{X} \in \mathbb{R}^{n\times p}$), el vector de medias muestral es $\bar{\mathbf{x}} = \dfrac{1}{n}\mathbf{X}'\mathbf{1}$.

Definición de variables (primera aparición). En esta expresión, $\boldsymbol{\mu}$ es vector de medias poblacionales ; $\mathbf{X}$ es vector aleatorio multivariante ; $\mathbf{x}_i$ es observación i de la muestra ; $\bar{\mathbf{x}}$ es vector de medias muestrales ; $\mathbf{1}$ es vector columna de unos de dimensión compatible .

Propiedades del vector de medias:

- Es el centro de gravedad euclídeo de la nube de puntos: haciendo nula la suma de desviaciones: $\sum_{i=1}^{n}(\mathbf{x}_i - \bar{\mathbf{x}}) = \mathbf{0}$.
- Es un **operador lineal**: $E[\mathbf{AX} + \mathbf{b}] = \mathbf{A}E[\mathbf{X}] + \mathbf{b}$.

4.2. Variabilidad: matriz de varianzas y covarianzas

Definición 4.2 (Matriz de varianzas y covarianzas)**.** En variables multivariantes, la variabilidad y la relación lineal entre variables se presenta de forma compacta en la **matriz de varianzas y covarianzas**:

$$\mathbf{S}_x = E\Big[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})'\Big] = \frac{1}{n}\sum_{i=1}^{n}(\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})'.$$

Definición de variables (primera aparición). En esta expresión, $\mathbf{S}_x$ es matriz de varianzas y covarianzas ; S_i^2 es varianza de la variable i ; S_{ij} es covarianza entre las variables i y j .

Explícitamente:

$$s_{jk} = \frac{1}{n}\sum_{i=1}^{n}(x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k), \qquad j, k = 1, \ldots, p,$$

$$\mathbf{S}_x = \begin{pmatrix} s_{11} & \cdots & s_{1p} \\ \vdots & \ddots & \vdots \\ s_{p1} & \cdots & s_{pp} \end{pmatrix}, \qquad s_{jj} = s_j^2.$$

Observación. La diagonal de $\mathbf{S}_x$ mide dispersión individual y los términos extradiagonales cuantifican dependencia lineal entre variables.

4.2.1. Matriz de datos centrados

Se define la **matriz de datos centrados** (o puntuaciones diferenciales) $\tilde{\mathbf{X}}$ como la matriz resultado de restar a cada dato su media:

$$\tilde{\mathbf{X}} = \mathbf{X} - \mathbf{1}\bar{\mathbf{x}}' = \mathbf{X} - \frac{1}{n}\mathbf{1}\mathbf{1}'\mathbf{X} = \mathbf{P}\mathbf{X},$$

y la **matriz de proyección** es:

$$\mathbf{P} = \mathbf{I} - \frac{1}{n}\mathbf{1} \cdot \mathbf{1}',$$

que es simétrica ($\mathbf{P} = \mathbf{P}'$) e **idempotente** ($\mathbf{P}^2 = \mathbf{P}$).

Definición de variables (primera aparición). En esta expresión, $\tilde{\mathbf{X}}$ es matriz de datos centrados ; $\mathbf{P}$ es matriz de proyección de centrado ; $\mathbf{I}$ es matriz identidad de orden n .

Por tanto:

$$\mathbf{S} = \frac{1}{n}\tilde{\mathbf{X}}'\tilde{\mathbf{X}} = \frac{1}{n}\mathbf{X}'\mathbf{P}\mathbf{X}.$$

La **matriz de varianzas corregida** (estimación insesgada) es:

$$\hat{\mathbf{S}} = \frac{1}{n-1}\tilde{\mathbf{X}}' \cdot \tilde{\mathbf{X}}.$$

4.2.2. S es semidefinida positiva

Proposición 4.3. *La matriz* $\mathbf{S}$ *es semidefinida positiva, es decir,* $\mathbf{y}'\mathbf{S}\mathbf{y} \geq 0$ *para todo* $\mathbf{y} \in \mathbb{R}^p$.

Demostración. Sea $\mathbf{w} \in \mathbb{R}^p$ *y definamos la combinación lineal centrada* $v_i = \mathbf{w}'(\mathbf{x}_i - \bar{\mathbf{x}})$*. Su media es nula y su varianza muestral:*

$$\mathrm{Var}(v) = \frac{1}{n}\sum_{i=1}^{n} v_i^2 = \frac{1}{n}\sum_{i=1}^{n}[\mathbf{w}'(\mathbf{x}_i - \bar{\mathbf{x}})][(\mathbf{x}_i - \bar{\mathbf{x}})'\mathbf{w}] = \mathbf{w}'\mathbf{S}\mathbf{w} \geq 0.$$

Como toda varianza es no negativa y $\mathbf{w}$ *es arbitrario,* $\mathbf{S}$ *es semidefinida positiva.* □

Consecuencias:

- Si $\mathbf{S}\mathbf{w}_i = \lambda_i \mathbf{w}_i$: $\lambda_i \geq 0$, todos los menores principales son no negativos y $|\mathbf{S}| \geq 0$.
- Si $\mathbf{S}$ tiene rango $h < p$, existen $r = p - h$ combinaciones lineales entre las variables, es decir r variables redundantes que pueden eliminarse. Se pueden representar las observaciones con $h = p - r$ variables.
- Cualquier vector del subespacio definido por $(\mathbf{w}_1, \ldots, \mathbf{w}_r)$ puede expresarse como combinación lineal y verifica $\mathbf{S}(a_1\mathbf{w}_1 + \cdots + a_r\mathbf{w}_r) = \mathbf{0}$. Los autovectores de $\mathbf{S}$ asociados a valores propios nulos constituyen una base ortonormal en dicho espacio.

4.2.3. Variabilidad total

Definición 4.4 (Variabilidad total)**.** Una forma de resumir la variabilidad de un conjunto de variables es mediante la traza de su matriz de varianzas y covarianzas:

$$T = \mathrm{tr}(\mathbf{S}) = \sum_{j=1}^{p} s_j^2.$$

Observación. Una dependencia alta entre variables implica una variabilidad conjunta pequeña. Esta medida prescinde de las relaciones de dependencia existentes.

4.2.4. Varianza generalizada

Definición 4.5 (Varianza generalizada)**.**

$$VG = |\mathbf{S}|.$$

Mide mejor la variabilidad global. Su raíz cuadrada se denomina **desviación típica generalizada**, y tiene las siguientes propiedades:

- Está bien definida (el determinante de la matriz de varianzas y covarianzas es siempre no negativo).
- Es una medida del área ($p = 2$), volumen ($p = 3$) o hipervolumen ($p > 3$) ocupado por el conjunto de datos.

Para $p = 2$:

$$\mathbf{S} = \begin{pmatrix} s_x^2 & r s_x s_y \\ r s_x s_y & s_y^2 \end{pmatrix}, \qquad |\mathbf{S}|^{1/2} = s_x s_y \sqrt{1 - r^2}.$$

Si las variables están relacionadas linealmente ($r \neq 0$), la mayoría de los puntos tenderán

a situarse en una franja alrededor de la recta de regresión, reduciéndose el área tanto mayor cuanto mayor sea r^2.

4.2.5. Distancias

Definición 4.6 (Distancia o métrica)**.** Dados dos puntos $\mathbf{x}_i, \mathbf{x}_j \in \mathbb{R}^p$, una **distancia** es una función $d(\mathbf{x}_i, \mathbf{x}_j)$ que satisface:

1. $d(\mathbf{x}_i, \mathbf{x}_j) \geq 0$ (no negatividad).
2. $d(\mathbf{x}_i, \mathbf{x}_i) = 0$ (identidad).
3. $d(\mathbf{x}_i, \mathbf{x}_j) = d(\mathbf{x}_j, \mathbf{x}_i)$ (simetría).
4. $d(\mathbf{x}_i, \mathbf{x}_j) \leq d(\mathbf{x}_i, \mathbf{x}_\ell) + d(\mathbf{x}_\ell, \mathbf{x}_j)$ (desigualdad triangular).

La distancia euclídea es la referencia geométrica básica, pero depende de escala y no incorpora correlaciones. Por ello, en multivariante se emplean también distancias ponderadas y, en particular, la de Mahalanobis.

Definición 4.7 (Distancia de Mahalanobis)**.** La distancia de Mahalanobis entre un punto $\mathbf{x}_i$ y el vector de medias $\bar{\mathbf{x}}$ se define como:

$$\boxed{d_M = \sqrt{(\mathbf{x}_i - \bar{\mathbf{x}})'\mathbf{S}^{-1}(\mathbf{x}_i - \bar{\mathbf{x}})}.}$$

Tiene en cuenta variabilidad y correlación, y es invariante frente a cambios lineales de coordenadas no singulares.

Para $p = 2$, siendo $s_{1,2} = r s_1 s_2$:

$$\mathbf{S}^{-1} = \frac{1}{1-r^2}\begin{pmatrix} s_1^{-2} & -r s_1^{-1} s_2^{-1} \\ -r s_1^{-1} s_2^{-1} & s_2^{-2} \end{pmatrix},$$

$$d_M^2 = \frac{1}{1-r^2}\left[\frac{\Delta x^2}{s_1^2} + \frac{\Delta y^2}{s_2^2} - 2r\frac{\Delta x\,\Delta y}{s_1 s_2}\right].$$

$$\text{donde } \Delta x = x_{i1} - \bar{x}_1, \quad \Delta y = x_{i2} - \bar{x}_2.$$

- Si $r = 0$: se reduce a la distancia euclídea estandarizada.
- Si r es baja: se aproxima a la euclídea y cada variable contribuye de forma independiente.
- Si r es alta: es menor que la euclídea y $\mathbf{S}$ reduce la contribución de las variables correlacionadas.
- Si $r = 1$: $\mathbf{S}$ es singular, una variable es redundante y la distancia es indefinida.

4.2.6. Distancia promedio

Podemos medir la variabilidad promediando las distancias entre los puntos y la media. Con distancias euclídeas:

$$V_m = \frac{1}{n}\sum_{i=1}^{n}(\mathbf{x}_i - \bar{\mathbf{x}})'(\mathbf{x}_i - \bar{\mathbf{x}}) = \sum_{i=1}^{n}\operatorname{tr}\left[\frac{1}{n}(\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})'\right] = \operatorname{tr}(\mathbf{S}).$$

El promedio de distancias es la variabilidad total. Si se promedia también por la dimensión del vector:

$$V_{m,p} = \frac{1}{np}\sum_{i=1}^{n}(\mathbf{x}_i - \bar{\mathbf{x}})'(\mathbf{x}_i - \bar{\mathbf{x}}) = \bar{s}^2.$$

5. Medidas de dependencia lineal

El objetivo fundamental de la descripción de datos multivariantes es comprender la estructura de dependencias entre las variables. Estas dependencias pueden estudiarse:

- Entre pares de variables.
- Entre una variable y el resto.
- Entre pares de variables eliminando el efecto de las demás.
- Entre el conjunto de todas las variables.

5.1. Dependencia entre pares: coeficiente de correlación

Definición 5.1 (Coeficiente de correlación lineal)**.**

$$r_{jk} = \frac{s_{jk}}{s_j s_k}, \qquad 0 \leq |r_{jk}| \leq 1.$$

Si existe relación lineal exacta ($x_{ij} = a + bx_{ik}$): $|r_{jk}| = 1$. Es invariante ante transformaciones lineales de las variables.

Definición 5.2 (Matriz de correlaciones)**.** La **matriz de correlaciones** del vector aleatorio $\mathbf{x}$ con matriz de covarianzas $\mathbf{S}_x$ es:

$$\boxed{\mathbf{R}_x = \mathbf{D}^{-\frac{1}{2}}\mathbf{S}_x\mathbf{D}^{-\frac{1}{2}}, \qquad \mathbf{D} = \operatorname{diag}(\sigma_1^2, \ldots, \sigma_p^2).}$$

$$\mathbf{R} = \begin{pmatrix} 1 & \cdots & r_{1p} \\ \vdots & \ddots & \vdots \\ r_{p1} & \cdots & 1 \end{pmatrix}.$$

Es una matriz cuadrada y simétrica con unos en la diagonal y coeficientes de correlación fuera. Es semidefinida positiva.

Observación. La fórmula anterior se obtiene al estandarizar cada variable por su desviación típica: si $\mathbf{Z} = (\mathbf{X} - \boldsymbol{\mu})\mathbf{D}^{-1/2}$, entonces $\operatorname{Cov}(\mathbf{Z}) = \mathbf{R}_x$.

Proposición 5.3. *La matriz de correlaciones $\mathbf{R}_x$ es simétrica y semidefinida positiva.*

Demostración. La simetría se hereda de $\mathbf{S}_x$. Además, para cualquier $\mathbf{u} \in \mathbb{R}^p$:

$$\mathbf{u}'\mathbf{R}_x\mathbf{u} = (\mathbf{D}^{-1/2}\mathbf{u})'\mathbf{S}_x(\mathbf{D}^{-1/2}\mathbf{u}) \geq 0,$$

porque $\mathbf{S}_x$ *es semidefinida positiva. Por tanto,* $\mathbf{R}_x$ *también es semidefinida positiva.* □

5.2. Dependencia entre una variable y el resto: regresión múltiple

Se estudia mediante **regresión múltiple**. El predictor lineal de la variable y es:

$$\hat{y}_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_k x_{ik} + e_i,$$

donde $e_i = y_i - \hat{y}_i$ son los errores de predicción. El criterio de mínimos cuadrados asigna a los β_j el valor que minimiza la suma de errores al cuadrado. Los residuos deben estar incorrelados con las variables explicativas (*covarianza cero*): el vector de residuos es ortogonal al espacio generado por las variables explicativas.

5.3. Correlación parcial: eliminando el efecto de las demás

Definición 5.4 (Coeficiente de correlación parcial)**.** El coeficiente de correlación parcial entre (x_1, x_2) dadas $(x_3, \ldots, x_p)$ se denota $r_{12.3\ldots p}$: es el coeficiente de correlación entre x_1 y x_2 que están libres de los efectos de $(x_3, \ldots, x_p)$.

Se calcula:

a) Se obtiene la parte de cada variable no explicada por el grupo de variables controladas: *residuo de la regresión sobre* $(x_3, \ldots, x_p)$.
b) Se calcula el coeficiente de correlación simple entre estos dos residuos.

Puede demostrarse que estandarizando los elementos de $\mathbf{S}^{-1}$, llamando s^{ij} a sus elementos:

$$\boxed{r_{jk.\,\text{resto}} = -\frac{s^{jk}}{\sqrt{s^{jj}s^{kk}}}.}$$

Observación. La expresión anterior muestra que la correlación parcial es nula exactamente cuando el término fuera de la diagonal correspondiente en la matriz de precisión $\mathbf{S}^{-1}$ es cero; este hecho conecta la dependencia condicional lineal con la estructura de la inversa de la covarianza.

La **matriz de correlaciones parciales P** contiene los coeficientes de correlación parcial entre pares de variables eliminando el efecto de las restantes. Por ejemplo, para cuatro variables:

$$\mathbf{P}_4 = \begin{pmatrix} 1 & r_{12.34} & r_{13.24} & r_{14.23} \\ r_{21.34} & 1 & r_{23.14} & r_{24.13} \\ r_{31.24} & r_{32.14} & 1 & r_{34.12} \\ r_{41.23} & r_{42.13} & r_{43.12} & 1 \end{pmatrix}.$$

5.4. Dependencia global: determinante de R

Definición 5.5 (Medida global de dependencia)**.** El **determinante de la matriz de correlación** mide lo alejado que está el conjunto de variables de la situación de dependencia lineal perfecta:

$$0 \leq |\mathbf{R}| \leq 1.$$

- Si las variables están todas incorreladas: $\mathbf{R}$ es diagonal con unos y $|\mathbf{R}| = 1$.
- Si una variable es combinación lineal del resto: $\mathbf{S}$, $\mathbf{R}$ son singulares y $|\mathbf{R}| = 0$.

Definición 5.6 (Dependencia D_p (Peña y Rodríguez, 2000))**.** Una medida global de las correlaciones lineales es:

$$D_p = 1 - |\mathbf{R}_p|^{1/(p-1)}.$$

Para $p = 2$: $|\mathbf{R}_p| = 1 - r_{12}^2$, luego $D_p = r_{12}^2$, que coincide con el coeficiente de determinación.

5.5. Matriz de precisión

Definición 5.7 (Matriz de precisión)**.** La **matriz de precisión** es la inversa de la matriz de varianzas y covarianzas: $\mathbf{S}^{-1}$. Contiene la información sobre la relación multivariante entre cada variable y el resto.

Sus elementos tienen la siguiente interpretación:

- **Fuera de la diagonal:** $s^{ij} = -\hat{\beta}_{ij}/s_r^2(i)$, donde $\hat{\beta}_{ij}$ es el coeficiente de regresión de la variable j para explicar la variable i, y $s_r^2(i)$ es la varianza residual de esa regresión.
- **En la diagonal:** $s^{ii} = 1/s_r^2(i)$ (inversas de las varianzas residuales de cada variable en su regresión con el resto).
- Si se estandarizan los elementos para que tenga unos en la diagonal, los elementos fuera de la diagonal son los coeficientes de correlación parcial: $r_{ij,R} = -s^{ij}/\sqrt{s^{ii}s^{jj}}$, donde R denota el conjunto de $p-2$ variables x_k con $k \neq i, j$.

Ejemplo 5.1.

$$\mathbf{S}^{-1} = \begin{pmatrix} 52{,}0942 & -47{,}9058 & 52{,}8796 \\ -47{,}9058 & 52{,}0942 & -47{,}1204 \\ 52{,}8796 & -47{,}1204 & 60{,}2094 \end{pmatrix}.$$

La primera fila puede escribirse como $52{,}0942 \times (1, -0{,}9196, 1{,}0151)$: los coeficientes de regresión de x_2 y x_3 para explicar x_1 son 0,9196 y $-1{,}0151$ respectivamente. La varianza residual de la regresión de x_1 sobre las otras dos es $1/52{,}0942 = 0{,}0192$.

6. Transformaciones de vectores aleatorios

6.1. Generalidades: función de densidad y cambio de variable

Definición 6.1 (Función de densidad)**.** La función de densidad describe la densidad de probabilidad en cualquier intervalo:

$$f(x_0) = \lim_{\Delta x \to 0^+} \frac{P(x_0 < X \leq x_0 + \Delta x)}{\Delta x}.$$

Al hacer las clases del histograma cada vez más pequeñas, éste tenderá a una curva $f(x)$ que describe el comportamiento de la variable.

Propiedades de $f(x)$:

1. $f(x) \geq 0 \quad \forall x \in \mathbb{R}$.
2. $P(a < x \leq b) = \displaystyle\int_a^b f(x)\,dx \quad \forall a, b \in \mathbb{R}$.
3. $P(X \leq x) = \displaystyle\int_{-\infty}^{x} f(x)\,dx$.
4. $\displaystyle\int_{-\infty}^{+\infty} f(x)\,dx = 1$.

Como la función de densidad tiene dimensiones, si cambian las unidades de medida, la función debe modificarse también.

Cambio de variable general.

Sea $\mathbf{x} \in \mathbb{R}^p$ con función de densidad $f_x(\mathbf{x})$ y sea otro vector aleatorio $\mathbf{y} \in \mathbb{R}^p$ definido por la transformación:

$$y_i = g_i(x_1, \ldots, x_p), \quad i = 1, \ldots, p.$$

Suponiendo que existen las funciones inversas $x_i = h_i(y_1, \ldots, y_p)$ y que todas son diferenciables, la transformación es biyectiva en el soporte y el jacobiano no se anula, la función de densidad de $\mathbf{y}$ es:

$$\boxed{f_y(\mathbf{y}) = f_x(\mathbf{x}) \left| \frac{d\mathbf{x}}{d\mathbf{y}} \right|,}$$

donde $\left| \dfrac{d\mathbf{x}}{d\mathbf{y}} \right|$ es el **jacobiano** de la transformación:

$$\left| \frac{d\mathbf{x}}{d\mathbf{y}} \right| = \begin{vmatrix} \partial x_1/\partial y_1 & \cdots & \partial x_1/\partial y_p \\ \vdots & & \vdots \\ \partial x_p/\partial y_1 & \cdots & \partial x_p/\partial y_p \end{vmatrix}.$$

Caso de transformaciones lineales.

Para $\mathbf{y} = \mathbf{A}\mathbf{x}$ con $\mathbf{A}$ cuadrada no singular: $\mathbf{x} = \mathbf{A}^{-1}\mathbf{y}$, luego $\partial\mathbf{x}/\partial\mathbf{y} = \mathbf{A}^{-1}$ y el jacobiano es $|\mathbf{A}^{-1}| = |\mathbf{A}|^{-1}$. Por tanto:

$$\boxed{f_y(\mathbf{y}) = f_x\Big(\mathbf{A}^{-1}\mathbf{y}\Big)\,|\mathbf{A}|^{-1}.}$$

Para obtener la función de densidad de $\mathbf{y}$, se sustituye el argumento en f_x por $\mathbf{A}^{-1}$ y se divide por $|\mathbf{A}|$.

6.2. Esperanzas de transformaciones lineales

Sea $\mathbf{X}$ un vector aleatorio de dimensión p y $\mathbf{Y} = \mathbf{AX}$ un nuevo vector de dimensión $m \leq p$ ($\mathbf{A}$ rectangular de dimensiones $m \times p$). Llamando $\boldsymbol{\mu}_x, \boldsymbol{\mu}_y$ a los vectores de medias y $\mathbf{S}_x, \mathbf{S}_y$ a las matrices de covarianzas:

$$\boxed{\boldsymbol{\mu}_y = \mathbf{A}\boldsymbol{\mu}_x, \qquad \mathbf{S}_y = \mathbf{A}\mathbf{S}_x\mathbf{A}'.}$$

Demostración. Por linealidad de la esperanza:

$$\boldsymbol{\mu}_y = E(\mathbf{Y}) = E(\mathbf{AX}) = \mathbf{A}E(\mathbf{X}) = \mathbf{A}\boldsymbol{\mu}_x.$$

Además,

$$\mathbf{S}_y = \mathrm{Cov}(\mathbf{Y}) = E\Big[(\mathbf{Y} - \boldsymbol{\mu}_y)(\mathbf{Y} - \boldsymbol{\mu}_y)'\Big] = E\big[\mathbf{A}(\mathbf{X} - \boldsymbol{\mu}_x)(\mathbf{X} - \boldsymbol{\mu}_x)'\mathbf{A}'\big]\,.$$

Como $\mathbf{A}$ *es constante respecto a la esperanza:*

$$\mathbf{S}_y = \mathbf{A}\,E\big[(\mathbf{X} - \boldsymbol{\mu}_x)(\mathbf{X} - \boldsymbol{\mu}_x)'\big]\,\mathbf{A}' = \mathbf{A}\mathbf{S}_x\mathbf{A}'.$$

□

Esperanzas condicionadas.

$$E(\mathbf{X}_1 \mid \mathbf{X}_2) = \int \mathbf{x}_1\, f(\mathbf{x}_1 \mid \mathbf{x}_2)\, d\mathbf{x}_1.$$

En general será función del valor de $\mathbf{X}_2$. Si $\mathbf{X}_2$ es fija, la esperanza condicionada es una constante; si es variable aleatoria, será una variable aleatoria.

7. Modelos de distribuciones multivariantes

7.1. Distribución multinomial

Definición 7.1 (Distribución multinomial)**.** Se observan elementos que se pueden clasificar en G clases. Si el proceso generador es estable se definen G variables aleatorias:

$$x_j = \begin{cases} 1 & \text{si la observación pertenece al grupo } j \\ 0 & \text{en otro caso} \end{cases}, \quad j = 1, \ldots, G.$$

El vector de probabilidades de pertenencia a las clases es $\mathbf{p} = (p_1, \ldots, p_G)'$ con $\sum p_j = 1$.

El resultado de una observación es un valor del vector de G-variables $\mathbf{x} = (x_1, \ldots, x_G)'$ de la forma $\mathbf{x} = (0, \ldots, 1, \ldots, 0)$ (el valor 1 corresponde a la clase observada).

Propiedades:

- $E[\mathbf{x}] = \mathbf{p}$.
- $\mathbf{S}_x = \mathrm{diag}(\mathbf{p}) - \mathbf{p}\mathbf{p}'$: las varianzas son $p_j(1-p_j)$ y las covarianzas $-p_j p_k$.

Si se realizan n observaciones independientes y n_j es el número de observaciones en la clase j, la **distribución multinomial** de $\mathbf{n} = (n_1, \ldots, n_G)'$ es:

$$P(\mathbf{n}) = \frac{n!}{n_1! \cdots n_G!} p_1^{n_1} \cdots p_G^{n_G}, \qquad \sum n_j = n.$$

7.2. Distribución de Dirichlet

Definición 7.2 (Distribución de Dirichlet)**.** La **distribución de Dirichlet** es la generalización multivariante de la distribución Beta. Se define sobre el símplex estándar $\mathcal{S}_G = \{(x_1, \ldots, x_G) : x_i \geq 0, \sum x_i = 1\}$ con parámetros $\boldsymbol{\alpha} = (\alpha_1, \ldots, \alpha_G)'$, $\alpha_i > 0$.
Su función de densidad es:

$$\boxed{f(x_1, \ldots, x_{G-1}) = \frac{\Gamma(\alpha_0)}{\prod_{i=1}^G \Gamma(\alpha_i)} \prod_{i=1}^G x_i^{\alpha_i - 1}, \qquad \alpha_0 = \sum_{i=1}^G \alpha_i.}$$

Propiedades:

- $E[x_i] = \dfrac{\alpha_i}{\alpha_0}$.
- $\mathrm{Var}[x_i] = \dfrac{\alpha_i(\alpha_0 - \alpha_i)}{\alpha_0^2(\alpha_0 + 1)}$.
- $\mathrm{Cov}[x_i, x_j] = -\dfrac{\alpha_i \alpha_j}{\alpha_0^2(\alpha_0 + 1)}$ para $i \neq j$.
- Cada marginal $x_i \sim \mathrm{Beta}(\alpha_i, \alpha_0 - \alpha_i)$.
- Es la distribución conjugada de la multinomial: si $\mathbf{p} \sim \mathrm{Dir}(\boldsymbol{\alpha})$ y se observan n_j eventos de clase j, la distribución a posteriori es $\mathrm{Dir}(\alpha_1 + n_1, \ldots, \alpha_G + n_G)$.

7.3. Distribución normal multivariante

La distribución más importante en el análisis multivariante es la **distribución normal multivariante**, base teórica de la mayoría de las técnicas clásicas.

Definición 7.3 (Normal multivariante)**.** Un vector aleatorio $\mathbf{X}$ de dimensión p sigue una distribución normal multivariante $\mathbf{X} \sim \mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ si su función de densidad es:

$$\boxed{f(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} |\boldsymbol{\Sigma}|^{1/2}} \exp\left\{-\tfrac{1}{2}(\mathbf{x} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})\right\}, \quad \mathbf{x} \in \mathbb{R}^p,}$$

Definición de variables (primera aparición). En esta expresión, $\boldsymbol{\Sigma}$ es matriz de covarianzas común, simétrica y definida positiva ; $|\boldsymbol{\Sigma}|$ es determinante de la matriz de covarianzas ; $\boldsymbol{\Sigma}^{-1}$ es matriz inversa de $\boldsymbol{\Sigma}$.

Propiedades fundamentales.

- **Marginales:** toda marginal de una normal multivariante es normal univariante: $X_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$.
- **Combinaciones lineales:** si $\mathbf{X} \sim \mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ y $\mathbf{Y} = \mathbf{AX} + \mathbf{b}$, entonces $\mathbf{Y} \sim \mathcal{N}_m(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}')$.
- **Independencia $\Leftrightarrow$ incorrelación:** en la normal multivariante, dos variables son independientes si y solo si su covarianza es nula. Equivalentemente, la matriz de covarianzas es diagonal si y solo si las componentes son independientes.
- **Distribución condicionada:** si particionamos $\mathbf{X} = (\mathbf{X}_1', \mathbf{X}_2')'$ con $\boldsymbol{\mu} = (\boldsymbol{\mu}_1', \boldsymbol{\mu}_2')'$ y $\boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{pmatrix}$, entonces:

$$\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2 \sim \mathcal{N}\Big(\boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2),\ \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}\Big).$$

- **Distancia de Mahalanobis:** la forma cuadrática $(\mathbf{X} - \boldsymbol{\mu})'\boldsymbol{\Sigma}^{-1}(\mathbf{X} - \boldsymbol{\mu}) \sim \chi^2(p)$ (distribución chi-cuadrado con p grados de libertad). Las superficies de igual densidad son elipsoides centrados en $\boldsymbol{\mu}$.
- **Estimación:** los estimadores de máxima verosimilitud son $\hat{\boldsymbol{\mu}} = \bar{\mathbf{x}}$ y $\hat{\boldsymbol{\Sigma}} = \frac{1}{n}\sum(\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})' = \mathbf{S}$. El estimador insesgado de $\boldsymbol{\Sigma}$ es $\hat{\mathbf{S}} = \frac{n}{n-1}\mathbf{S}$.

Tema 3

Análisis de Componentes Principales

1. Introducción

El **Análisis de Componentes Principales (ACP)** es un tipo de análisis factorial —junto con el Análisis Factorial de Correlaciones y el Análisis de Correspondencias— cuyo objetivo es analizar la estructura de las correlaciones entre un gran número de variables mediante la definición de una serie de *dimensiones subyacentes o factores*.

Formalmente, ACP construye una base ortogonal adaptada a la nube de datos: ordena direcciones por varianza explicada y permite representar el problema en dimensión reducida con pérdida controlada.

- Es una **técnica de interdependencia**: se consideran todas las variables simultáneamente, cada una relacionada con todas las demás.
- Usa el **valor teórico** (combinación lineal de las variables).
- Los valores teóricos (factores o componentes) tratan de maximizar la explicación de la serie de variables, *no* de predecir variables dependientes.
- Permite la **síntesis** de un gran conjunto de datos: la información contenida se representa mediante un conjunto de variables (componentes), función lineal de las originales, de número menor.
- Los componentes suelen interpretarse como **factores responsables de la variabilidad observada**.

La idea geométrica central es proyectar los datos sobre subespacios de menor dimensión maximizando la varianza retenida (equivalentemente, minimizando error cuadrático de reconstrucción).

Nota. El origen de la técnica se debe a **Karl Pearson (1901)**, que la introdujo como un medio de ajustar hiperplanos según el criterio de mínimos cuadrados ortogonales. Fue establecida formalmente por **Harold Hotelling (1933)** y desarrollada gracias a los avances informáticos del siglo XX y XXI.

Dado un conjunto de n observaciones de p variables, se trata de representar adecuadamente esta información con un número menor de variables construidas como combinaciones lineales de las originales:

> Con variables de alta dependencia es frecuente que un pequeño número de nuevas variables (<20 % de las originales) expliquen la mayor parte (>80 %) de la variabilidad original.

La técnica permite:

- Representar óptimamente observaciones de un espacio p-dimensional en un espacio de dimensión más reducida (primer paso para identificar variables “latentes” o no

observadas que generan la variabilidad).

- Transformar las variables originales, en general correladas, en nuevas variables incorreladas, facilitando la interpretación de los datos.

Cuestiones prácticas.

- No deben usarse muestras inferiores a 50 observaciones (idealmente 100 o más).
- Como regla general, la muestra mínima debería ser **cinco veces mayor** que el número de variables analizadas; el tamaño aceptable es un ratio de **diez a uno**.
- Si se incluyen indiscriminadamente grandes cantidades de variables esperando que el análisis factorial lo solucione, la posibilidad de obtener malos resultados es alta.

2. Planteamiento del problema

Partimos de variables $\mathbf{x}_1, \mathbf{x}_2, \ldots, \mathbf{x}_p$ medidas sobre n unidades observacionales $\Rightarrow$ matriz $\mathbf{X}$ de orden $n \times p$. Queremos unas nuevas variables latentes o **componentes** $\mathbf{y}_1, \mathbf{y}_2, \ldots, \mathbf{y}_p$ que:

Definición de variables (primera aparición). En esta expresión, $\mathbf{y}_j$ es componente principal j .

a) No establezcan ningún requisito sobre la distribución de $\mathbf{x}_1, \mathbf{x}_2, \ldots, \mathbf{x}_p$. (*No requiere normalidad, aunque si puede asumirse la interpretación es más sencilla y pueden llevarse a cabo pruebas de significación.*)

b) Sean **combinaciones lineales** de $\mathbf{x}_1, \mathbf{x}_2, \ldots, \mathbf{x}_p$, por lo que hay el mismo número de componentes que de variables.

c) $\mathrm{var}(\mathbf{y}_1) \geq \mathrm{var}(\mathbf{y}_2) \geq \cdots \geq \mathrm{var}(\mathbf{y}_p)$.

d) $\mathrm{corr}(\mathbf{y}_i, \mathbf{y}_j) = 0 \ \forall i \neq j$, por lo que no existen restricciones de linealidad entre componentes y la matriz de covarianzas de los componentes es diagonal. En la práctica, $\mathbf{S}$ y $\mathbf{R}$ son semidefinidas positivas, y serán definidas positivas cuando no exista colinealidad exacta.

e) $\displaystyle\sum_{i=1}^{p} \mathrm{var}(\mathbf{y}_i) = \sum_{i=1}^{p} \mathrm{var}(\mathbf{x}_i)$.

Suponemos variables centradas (media 0), de modo que $\mathbf{X}$ tiene covarianza $\frac{1}{n}\mathbf{X}'\mathbf{X}$. Se trata de encontrar un **subespacio de dimensión menor que** p tal que, al proyectar sobre él los puntos, conserven su estructura con la menor distorsión posible (distancias entre puntos originales y proyecciones lo más pequeñas posible).

2.1. Proyección y criterio de maximización

Si consideramos un punto $\mathbf{x}_i$ y una dirección $\mathbf{a}_1 = (a_{11}, \ldots, a_{1p})'$ de norma unidad, la proyección de x_i sobre esta dirección es:

$$z_i = a_{11}x_{i1} + \cdots + a_{1p}x_{ip} = \mathbf{a}_1'\mathbf{x}_i,$$

y el vector que representa esta proyección es $z_i\mathbf{a}_1$.

Definición de variables (primera aparición). En esta expresión, $\mathbf{a}_1$ es dirección del primer componente (vector de pesos) ; z_i es proyección escalar de la observación $\mathbf{x}_i$ sobre $\mathbf{a}_1$; r_i es distancia entre la observación y su proyección en la dirección elegida .

Por el teorema de Pitágoras: $\mathbf{x}_i'\mathbf{x}_i = z_i^2 + r_i^2$, y sumando para todos los puntos:

$$\sum_{i=1}^{n} \mathbf{x}_i'\mathbf{x}_i = \sum_{i=1}^{n} z_i^2 + \sum_{i=1}^{n} r_i^2 \quad \text{(constante)}.$$

Por tanto:

$$\text{mín} \sum_{i=1}^{n} r_i^2 \iff \text{máx} \sum_{i=1}^{n} z_i^2.$$

Como las z_i tienen media 0 ($\bar{z} = \mathbf{a}_1'\bar{\mathbf{x}} = 0$), **maximizar la suma de cuadrados de las proyecciones equivale a maximizar su varianza**.

3. Cálculo de los componentes

3.1. Cálculo del primer componente

Buscamos una combinación lineal $\mathbf{z}_1 = \mathbf{X}\mathbf{a}_1$ con **varianza máxima**. Como $\mathbf{z}_1$ tiene media 0:

$$\text{var}(\mathbf{z}_1) = \frac{1}{n}\mathbf{z}_1'\mathbf{z}_1 = \frac{1}{n}\mathbf{a}_1'\mathbf{X}'\mathbf{X}\mathbf{a}_1 = \mathbf{a}_1'\mathbf{S}\mathbf{a}_1.$$

Imponemos la restricción $\mathbf{a}_1'\mathbf{a}_1 = 1$ mediante un multiplicador de Lagrange:

$$\mathcal{L} = \mathbf{a}_1'\mathbf{S}\mathbf{a}_1 - \lambda(\mathbf{a}_1'\mathbf{a}_1 - 1).$$

Definición de variables (primera aparición). En esta expresión, $\mathbf{S}$ es matriz de covarianzas de las variables originales ; $\mathcal{L}$ es función de Lagrange del problema de optimización ; λ es multiplicador de Lagrange que resulta ser un autovalor de $\mathbf{S}$.

Derivando e igualando a cero:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{a}_1} = 2\mathbf{S}\mathbf{a}_1 - 2\lambda\mathbf{a}_1 = 0 \quad \Longrightarrow \quad \mathbf{S}\mathbf{a}_1 = \lambda\mathbf{a}_1.$$

$\mathbf{a}_1$ es un **autovector** de la matriz $\mathbf{S}$ y λ su correspondiente autovalor. Como $\mathbf{a}_1'\mathbf{S}\mathbf{a}_1 = \lambda\mathbf{a}_1'\mathbf{a}_1 = \lambda$, la varianza del componente es el autovalor: $\text{var}(\mathbf{z}_1) = \lambda$.

Para maximizarla, λ debe ser el **mayor valor propio de S**, y $\mathbf{a}_1$ su vector asociado define los coeficientes de cada variable en el primer componente principal.

Este paso conecta de forma directa optimización y espectro de $\mathbf{S}$: maximizar varianza bajo restricción de norma equivale a seleccionar el autovector principal.

Proposición 3.1 (Caracterización variacional del primer componente)**.** *El primer componente principal maximiza el cociente de Rayleigh:*

$$\arg\max_{\mathbf{a}\neq\mathbf{0}} \frac{\mathbf{a}'\mathbf{S}\mathbf{a}}{\mathbf{a}'\mathbf{a}} = \mathbf{a}_1,$$

y el máximo alcanzado es el mayor autovalor de $\mathbf{S}$*.*

Demostración. Como $\mathbf{S}$ *es simétrica, admite descomposición espectral* $\mathbf{S} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}'$*, con* $\lambda_1 \geq \cdots \geq \lambda_p \geq 0$*. Si* $\mathbf{a} = \mathbf{U}\mathbf{c}$ *y* $\|\mathbf{a}\|^2 = \|\mathbf{c}\|^2 = 1$*:*

$$\mathbf{a}'\mathbf{S}\mathbf{a} = \mathbf{c}'\mathbf{\Lambda}\mathbf{c} = \sum_{j=1}^{p} \lambda_j c_j^2 \leq \lambda_1 \sum_{j=1}^{p} c_j^2 = \lambda_1.$$

La cota se alcanza tomando $\mathbf{c} = (1, 0, \ldots, 0)'$*, es decir,* $\mathbf{a} = \mathbf{a}_1$ *(autovector asociado a* λ_1*).* □

3.2. Cálculo del segundo componente

El segundo componente:

a) Deberá ser **ortogonal** al primero: $\mathbf{a}_1'\mathbf{a}_2 = 0$.
b) De entre las infinitas direcciones ortogonales posibles, escogemos la que extraiga el máximo de la varianza que queda sin explicar.

La suma de las varianzas de $\mathbf{z}_1 = \mathbf{X}\mathbf{a}_1$ y $\mathbf{z}_2 = \mathbf{X}\mathbf{a}_2$ debe ser máxima:

$$\mathcal{L} = \mathbf{a}_1'\mathbf{S}\mathbf{a}_1 + \mathbf{a}_2'\mathbf{S}\mathbf{a}_2 - \lambda_1(\mathbf{a}_1'\mathbf{a}_1 - 1) - \lambda_2(\mathbf{a}_2'\mathbf{a}_2 - 1).$$

Derivando:

$$\mathbf{S}\mathbf{a}_1 = \lambda_1\mathbf{a}_1, \qquad \mathbf{S}\mathbf{a}_2 = \lambda_2\mathbf{a}_2.$$

$\mathbf{a}_1$ y $\mathbf{a}_2$ son autovectores de $\mathbf{S}$. Tomando vectores propios de norma uno: $\mathcal{L} = \lambda_1 + \lambda_2$. Como $\mathbf{a}_1'\mathbf{a}_2 = 0$: $\mathrm{cov}(\mathbf{z}_1, \mathbf{z}_2) = \mathbf{a}_1'\mathbf{S}\mathbf{a}_2 = 0$, con lo que $\mathbf{z}_1$ y $\mathbf{z}_2$ están **incorreladas**.

3.3. Generalización

Proposición 3.2. *Sea* $h = \mathrm{r}(\mathbf{S}) \leq \min(n, p)$*. Existen* p *componentes principales algebraicamente definidos, pero solo* h *tienen varianza estrictamente positiva. Se obtienen calculando los autovalores* $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p \geq 0$ *de la ecuación característica:*

$$|\mathbf{S} - \lambda\mathbf{I}| = 0, \qquad (\mathbf{S} - \lambda_i\mathbf{I})\mathbf{a}_i = 0.$$

Los λ_i son reales y no negativos, al ser $\mathbf{S}$ *simétrica semidefinida positiva.*

Llamando $\mathbf{Z}$ a la matriz cuyas columnas son los valores de las p componentes en los n individuos, las nuevas variables se relacionan con las originales mediante:

$$\boxed{\mathbf{Z} = \mathbf{X}\mathbf{A}, \qquad \mathbf{A}'\mathbf{A} = \mathbf{I},}$$

donde $\mathbf{A}$ contiene en columnas los autovectores normalizados. Calcular los componentes principales equivale a aplicar una **transformación ortogonal** a las variables $\mathbf{X}$ (ejes originales) para obtener nuevas variables $\mathbf{Z}$ incorreladas entre sí: se eligen nuevos ejes coordenados que coincidan con los *ejes naturales* de los datos.

Proposición 3.3 (Covarianza de las puntuaciones principales)**.** *Si* $\mathbf{Z} = \mathbf{X}_c\mathbf{A}$*, con* $\mathbf{A}'\mathbf{A} = \mathbf{I}$ *y columnas de* $\mathbf{A}$ *formadas por autovectores de* $\mathbf{S}$*, entonces:*

$$\mathrm{Cov}(\mathbf{Z}) = \mathbf{A}'\mathbf{S}\mathbf{A} = \mathbf{\Lambda},$$

es decir, las componentes principales son incorreladas y sus varianzas son los autovalores de $\mathbf{S}$*.*

Demostración. Como $\mathbf{X}_c$ *está centrada,* $\mathrm{Cov}(\mathbf{Z}) = \frac{1}{n}\mathbf{Z}'\mathbf{Z}$*. Sustituyendo* $\mathbf{Z} = \mathbf{X}_c\mathbf{A}$*:*

$$\mathrm{Cov}(\mathbf{Z}) = \frac{1}{n}\mathbf{A}'\mathbf{X}_c'\mathbf{X}_c\mathbf{A} = \mathbf{A}'\mathbf{S}\mathbf{A}.$$

Si $\mathbf{S}\mathbf{A} = \mathbf{A}\mathbf{\Lambda}$*, entonces* $\mathbf{A}'\mathbf{S}\mathbf{A} = \mathbf{A}'\mathbf{A}\mathbf{\Lambda} = \mathbf{\Lambda}$*.* □

4. Propiedades de los componentes

1. **Conservación de la variabilidad total.** La suma de varianzas de los componentes es igual a la suma de varianzas de las variables originales, y la varianza generalizada de los componentes es igual a la original:

$$\mathrm{tr}(\mathbf{S}) = \sum_{j=1}^{p} \mathrm{Var}(X_j) = \lambda_1 + \cdots + \lambda_p = \sum_{j=1}^{p} \mathrm{Var}(Z_j).$$

   Si llamamos $\mathbf{S}_z$ a la matriz de covarianzas de los componentes (diagonal con términos λ_i):

$$|\mathbf{S}_z| = \lambda_1 \cdots \lambda_p = \prod_{j=1}^{p} \mathrm{Var}(Z_j).$$

2. **Proporción de variabilidad explicada.** La proporción de variabilidad total explicada por el componente h es:

$$c_h = \frac{\lambda_h}{\sum_i \lambda_i}.$$

3. **Covarianzas entre componentes y variables originales.**

$$\mathrm{cov}(z_i; x_1, \ldots, x_p) = \lambda_i \mathbf{a}_i = (\lambda_i a_{i1}, \ldots, \lambda_i a_{ip}).$$

La matriz $p \times p$ de covarianzas entre componentes y variables originales es:

$$\mathrm{Cov}(\mathbf{Z}, \mathbf{X}) = \frac{1}{n}\mathbf{Z}'\mathbf{X} = \mathbf{A}'\mathbf{S} = \mathbf{\Lambda}\mathbf{A}',$$

donde $\mathbf{A}$ contiene en columnas los vectores propios de $\mathbf{S}$ y $\mathbf{\Lambda}$ es la matriz diagonal de valores propios.

4. **Correlación entre un componente y una variable.** La correlación entre el componente z_i y la variable x_j es proporcional al coeficiente de esa variable en la definición del componente:

$$r(z_i, x_j) = \frac{\mathrm{cov}(z_i, x_j)}{\sqrt{\mathrm{var}(z_i)\,\mathrm{var}(x_j)}} = \frac{\lambda_i a_{ij}}{\sqrt{\lambda_i s_j^2}} = a_{ij}\frac{\sqrt{\lambda_i}}{s_j}.$$

El coeficiente de proporcionalidad es el cociente entre la desviación típica del componente y la de la variable.

5. **Predicción óptima.** Las r componentes principales ($r < p$) proporcionan la **predicción lineal óptima** del conjunto de variables $\mathbf{X}$.

5. Análisis con correlaciones (análisis normado)

Los componentes principales se obtienen maximizando la varianza de la proyección. En términos de las variables originales:

$$\text{máx}\, M = \sum_{i=1}^{p} a_i^2 s_i^2 + 2\sum_{i=1}^{p}\sum_{j=i+1}^{p} a_i a_j s_{ij}, \qquad \mathbf{a}'\mathbf{a} = 1.$$

Cuando las escalas de medida son muy distintas, la maximización dependerá de estas escalas y las variables con valores más grandes tendrán más peso. La solución es **estandarizar las variables antes de calcular los componentes**, con lo que la expresión se reduce a:

$$1 + 2\sum_{i=1}^{p}\sum_{j=i+1}^{p} a_i a_j r_{ij},$$

siendo r_{ij} el coeficiente de correlación $\Rightarrow$ la solución depende de las *correlaciones*, no de las varianzas.

En términos prácticos:

- ACP sobre $\mathbf{S}$ responde a la pregunta "qué direcciones maximizan variabilidad absoluta".
- ACP sobre $\mathbf{R}$ responde a "qué direcciones maximizan estructura correlacional, eliminando efecto de escala".

- Si las variables originales están en **distintas unidades**, conviene aplicar el análisis de la matriz de correlaciones (*análisis normado*).
- Si tienen las mismas unidades, ambas alternativas son posibles.

- Si las diferencias de varianzas son informativas, no se deben estandarizar las variables.

Los **componentes principales normados** se obtienen calculando los vectores y valores propios de la matriz $\mathbf{R}$. Llamando λ_i^R a los autovalores de esa matriz (suponemos no singular):

$$\sum_{i=1}^{p} \lambda_i^R = \operatorname{tr}(\mathbf{R}) = p.$$

Propiedades de los componentes extraídos de R.

- La proporción de varianza explicada por la componente j es: $\dfrac{\lambda_j^R}{p}$.
- Las correlaciones entre cada componente z_j y las variables X originales vienen dadas por: $\mathbf{a}_j'\sqrt{\lambda_j}$, siendo $\mathbf{z}_j = \mathbf{X}\mathbf{a}_j$.

6. Matriz de saturaciones o de cargas factoriales

Definición 6.1 (Matriz de saturaciones)**.** La **matriz de saturaciones F** muestra las correlaciones entre las variables originales y los componentes principales. Se calcula como:

$$\boxed{\mathbf{F} = \mathbf{A}\mathbf{\Lambda}^{1/2},}$$

donde $\mathbf{A}$ es la matriz de autovectores normalizados de la matriz analizada y $\mathbf{\Lambda}$ la matriz diagonal de autovalores.

Interpretativamente, cada carga factorial es una correlación variable– componente: magnitud alta implica fuerte asociación de la variable con el eje latente correspondiente.

- Cada **fila** representa una variable original.
- Cada **columna** representa un componente principal.
- Cuanto mayor es el valor absoluto de una saturación para un componente, más fuerte es la relación entre esa variable y el componente.
- Se interpreta como la **matriz del cambio de la base original** a la base constituida por los componentes.
- Expresada en puntuaciones típicas, las saturaciones son las correlaciones entre cada X_i e Y_i: $\mathbf{D}^{-1/2}\mathbf{A}\mathbf{\Lambda}^{1/2} = \mathbf{R}_{xy}$, siendo $\mathbf{D} = \operatorname{diag}(s_1^2, \ldots, s_p^2)$ la matriz diagonal de varianzas de las variables originales.

7. Resumen: cálculo de los componentes principales

A partir de la matriz S

I) Cálculo de la matriz de covarianzas: $\mathbf{S} = \dfrac{\mathbf{X}_c'\mathbf{X}_c}{n-1}$, donde $\mathbf{X}_c$ es la matriz de datos centrados.

II) Cálculo de la matriz $\mathbf{\Lambda}$ de autovalores de $\mathbf{S}$: $|\mathbf{S} - \lambda\mathbf{I}| = 0$.
III) Cálculo de la matriz $\mathbf{A}$ de autovectores: $(\mathbf{S} - \lambda_i\mathbf{I})\mathbf{a}_i = 0$ (autovectores normalizados de $\mathbf{S}$; el primero corresponde a la mayor raíz latente).
IV) Cálculo de la matriz $\mathbf{F}$ de saturaciones: $\mathbf{F} = \mathbf{A}\mathbf{\Lambda}^{1/2}$.
V) Cálculo de la matriz de puntuaciones de los sujetos en los componentes: $\mathbf{Y} = \mathbf{X}_c\mathbf{A}$.
VI) Cálculo de la varianza de cada componente: $\mathrm{var}(Y_i) = \mathbf{a}_i'\mathbf{S}\mathbf{a}_i = \lambda_i$.
VII) Cálculo de la proporción de varianza explicada: $c_i = \lambda_i / \sum \lambda_i$.

A partir de la matriz R

I) Cálculo de la matriz de correlaciones: $\mathbf{R} = \dfrac{\mathbf{Z}_x'\mathbf{Z}_x}{n-1}$, con $\mathbf{Z}_x$ datos tipificados.
II) Cálculo de la matriz $\mathbf{\Lambda}$ de autovalores de $\mathbf{R}$: $|\mathbf{R} - \lambda\mathbf{I}| = 0$.
III) Cálculo de la matriz $\mathbf{A}$ de autovectores: $(\mathbf{R} - \lambda_i\mathbf{I})\mathbf{a} = 0$.
IV) Cálculo de la matriz $\mathbf{F}$ de saturaciones: $\mathbf{F} = \mathbf{R}_{\mathbf{z}_x,\mathbf{z}_y} = \mathbf{A}\mathbf{\Lambda}^{1/2}$.
V) Cálculo de la matriz de puntuaciones típicas: $\mathbf{Z}_y = \mathbf{Z}_x\mathbf{A}$.
VI) Cálculo de la varianza de cada componente: $\mathrm{var}(\mathbf{z}_{y_i}) = \mathbf{A}'\mathbf{R}\mathbf{A} = \mathbf{\Lambda} = \mathbf{a}_i'\mathbf{R}\mathbf{a}_i = \lambda_i$; $\mathrm{cov}(\mathbf{z}_x, \mathbf{z}_y) = \mathbf{A}\mathbf{\Lambda}$.
VII) Cálculo de la proporción de varianza explicada: $c_i = \lambda_i / p$.

8. Interpretación de los componentes

8.1. Interpretación geométrica

Las combinaciones lineales $\mathbf{Y} = \mathbf{X}\mathbf{A}$ representan un nuevo sistema de coordenadas obtenido mediante una **rotación ortogonal a través del origen**:

$$X_1, X_2, \ldots, X_p \xrightarrow{\text{rotación ortogonal}} Y_1, Y_2, \ldots, Y_p.$$

La rotación es ortogonal porque $\mathbf{A}$ es una matriz ortogonal que, para dos componentes, puede expresarse como:

$$\mathbf{A} = \begin{pmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{pmatrix}.$$

La matriz $\mathbf{A}$ rota los ejes $X_1, X_2, \ldots, X_p$ un ángulo θ de manera que el primer componente reúna el máximo de la varianza contenida en los datos (y el segundo la restante).

Ejemplo 8.1.

$$\mathbf{A} = \begin{pmatrix} 0{,}722 & -0{,}692 \\ 0{,}692 & 0{,}722 \end{pmatrix}, \quad \cos\theta = 0{,}722, \quad \sin\theta = 0{,}692 \quad \Rightarrow \quad \theta = 43{,}78^\circ.$$

Los ejes se han girado $43{,}78^\circ$ de manera que el componente y_1 tiene gran variabilidad y el componente y_2 muy pequeña.

8.2. Interpretación sustantiva

- **Alta correlación positiva** entre todas las variables $\Rightarrow$ primer componente principal con todas sus coordenadas del mismo signo. Puede interpretarse como un *promedio ponderado* de todas las variables $\Rightarrow$ factor global de "tamaño".
- Las **restantes componentes** se interpretan como factores "de forma", con coordenadas positivas y negativas que contraponen unos grupos de variables frente a otros.

9. Número de factores a extraer

No se ha desarrollado una base cuantitativa exacta para decidir el número de componentes a extraer. Los criterios más habituales son:

I) **Criterio de raíz latente (Kaiser-Guttman, 1954):** cualquier factor individual debería justificar la varianza de al menos una variable. Se consideran significativos todos los factores con autovalores ≥ 1 (los que explican menos de una variable se desestiman).
   - Es más fiable cuando $20 \leq p \leq 50$.
   - $p < 20$: criterio conservador (demasiados pocos factores).
   - $p > 50$: demasiados factores.

   Es una regla arbitraria: una variable independiente del resto puede tener autovalor > 1, pero si está incorrelada con el resto puede ser poco relevante para el análisis.

II) **Criterio a priori:** se fija el número de factores antes de realizar el análisis.

III) **Criterio del porcentaje de la varianza:** se basa en obtener un porcentaje acumulado especificado de la varianza total.
   - Ciencias naturales: $\geq 95\,\%$ de la varianza total.
   - Ciencias sociales: $\geq 60\,\%$ de la varianza total.

   La regla es de nuevo arbitraria y debe aplicarse con cuidado: pueden existir componentes fuera de esos porcentajes muy adecuados para explicar la "forma" de las variables.

IV) **Gráfico de desmoronamiento o *scree plot*:** gráfico de λ_i frente a i. Las componentes se seleccionan hasta que las restantes tengan aproximadamente el mismo valor de λ_i ("codo" en el gráfico). A partir de ese punto los autovalores no aportan información adicional relevante.

10. Rotaciones

Extraer componentes para que tengan varianza máxima puede conducir a componentes muy complejas (correlación con la mayor parte de las variables originales), lo que dificulta la interpretación. Para facilitarla, se pueden **transformar los componentes mediante una rotación** (cambio de base):

- Se utiliza sobre todo en **análisis factorial**.

- La determinación del ángulo de rotación de las p componentes obtenidas se lleva a cabo con criterios matemáticos de optimización.

Definición 10.1 (Rotación Varimax (Kaiser, 1958))**.** El método más utilizado. Es una **rotación ortogonal** que simplifica por columnas maximizando la varianza de las saturaciones de cada componente.

El resultado es que las columnas pasan a tener **patrones de saturaciones muy dispersos**:

- Cargas elevadas en un solo factor y bajas en los otros.
- Mejor identificación de las variables más relacionadas con cada factor, mejorando la interpretación y la claridad de los resultados.

Observación. Otras rotaciones ortogonales: Quartimax (simplifica filas), Equimax (compromiso). Rotaciones oblicuas (factores correlados): Oblimin, Promax. Las rotaciones no alteran la varianza total explicada, solo redistribuyen la varianza entre los componentes.

Tema 4

Análisis Discriminante

1. Introducción

El **Análisis Discriminante Lineal** (ADL o *LDA*) es una técnica de **clasificación supervisada**: los grupos están definidos a priori y se construye una regla para asignar nuevas observaciones al grupo más probable según sus variables explicativas.

- Es un método clásico de **reconocimiento de patrones**.
- Los grupos deben ser **mutuamente excluyentes** y, en el esquema estándar, **exhaustivos**.
- Es apropiado cuando la variable respuesta es **cualitativa** (grupos) y las variables predictoras son **cuantitativas**.
- Se apoya en una combinación lineal de predictores, análoga al valor teórico ya estudiado en temas previos.
- Se necesita una **muestra de entrenamiento** (grupo conocido) y, para evaluar el rendimiento, una **muestra de validación** (*test sample*) o validación cruzada.
- En variables de respuesta ordinales puede usarse un *enfoque de extremos polares* (comparar solo grupos extremos), útil en algunos contextos aunque con pérdida de información intermedia.

Hipótesis canónicas del LDA clásico:

1. Normalidad multivariante dentro de cada clase.
2. Matriz de covarianzas común entre clases.
3. Independencia entre observaciones.
4. Colinealidad no exacta entre predictores.

Definición 1.1 (Función discriminante lineal)**.** Para una observación k, una función discriminante lineal puede escribirse como:

$$z_k = a + w_1 x_{1k} + w_2 x_{2k} + \cdots + w_p x_{pk}.$$

Definición de variables (primera aparición). En esta expresión, z_k es puntuación discriminante de la observación k ; a es término independiente de la función discriminante ; x_{jk} es valor de la variable j en la observación k .

Los pesos w_i se eligen para **maximizar la separación entre grupos** frente a la variabilidad dentro de los grupos.

Cada grupo tiene un **centroide** (media de puntuaciones discriminantes). Cuanto más separados estén los centroides, mayor capacidad discriminante.

Nota. El enfoque clásico se debe a **Fisher (1936)** y es óptimo bajo normalidad multivariante con matriz de covarianzas común en los grupos. Cuando estos supuestos fallan, se suelen considerar alternativas como QDA, regresión logística multinomial, árboles, k-NN o SVM.

2. Caso de dos poblaciones

2.1. Enfoque bayesiano general

Sean dos poblaciones $\mathcal{P}_1, \mathcal{P}_2$ con densidades $f_1(\mathbf{x})$, $f_2(\mathbf{x})$ y probabilidades a priori π_1, π_2 ($\pi_1 + \pi_2 = 1$). Para un nuevo elemento $\mathbf{x}_0$:

$$\boxed{P(\mathcal{P}_i \mid \mathbf{x}_0) = \frac{\pi_i f_i(\mathbf{x}_0)}{\pi_1 f_1(\mathbf{x}_0) + \pi_2 f_2(\mathbf{x}_0)}, \qquad i = 1, 2.}$$

Definición de variables (primera aparición). En esta expresión, $\mathcal{P}_i$ es población o clase i ; π_i es probabilidad a priori de la clase i ; $f_i(\mathbf{x})$ es densidad de $\mathbf{x}$ en la clase i ; $\mathbf{x}_0$ es nueva observación a clasificar ; $P(\mathcal{P}_i \mid \mathbf{x}_0)$ es probabilidad a posteriori de pertenecer a la clase i .

Regla bayesiana básica: asignar $\mathbf{x}_0$ al grupo con mayor probabilidad a posteriori; equivalentemente, al grupo que maximiza $\pi_i f_i(\mathbf{x}_0)$. Esta equivalencia permite pasar de una regla probabilística a una regla operativa de decisión.

2.1.1. Regla con costes de clasificación

Si el coste de clasificar en 2 algo de 1 es $c(2|1)$ y el coste inverso es $c(1|2)$:

Definición 2.1 (Regla de decisión)**.** Una regla de decisión particiona el espacio muestral $\mathcal{E}_{\mathbf{x}}$ en dos regiones $\mathcal{A}_1, \mathcal{A}_2$:

$$\mathcal{A}_2 = \mathcal{E}_{\mathbf{x}} \setminus \mathcal{A}_1, \qquad \mathbf{x}_0 \in \mathcal{A}_i \Rightarrow \text{asignar a } \mathcal{P}_i.$$

Si se conocen costes de clasificación, se asigna a la clase con **menor riesgo condicional esperado**.

$$R(d_1 \mid \mathbf{x}_0) = c(1|2)\, P(\mathcal{P}_2 \mid \mathbf{x}_0), \qquad R(d_2 \mid \mathbf{x}_0) = c(2|1)\, P(\mathcal{P}_1 \mid \mathbf{x}_0).$$

Se asigna a $\mathcal{P}_2$ si $R(d_2 \mid \mathbf{x}_0) < R(d_1 \mid \mathbf{x}_0)$, es decir:

$$\boxed{c(1|2)\, \pi_2 f_2(\mathbf{x}_0) > c(2|1)\, \pi_1 f_1(\mathbf{x}_0).}$$

- Si $c(1|2) = c(2|1)$, la decisión depende de $\pi_i f_i(\mathbf{x}_0)$.
- Si además $\pi_1 = \pi_2$, la regla se reduce a comparar densidades: clasificar en la población con mayor verosimilitud en $\mathbf{x}_0$.

2.2. Enfoque bayesiano en poblaciones normales

Si $\mathbf{X} \mid \mathcal{P}_i \sim \mathcal{N}_p(\boldsymbol{\mu}_i, \boldsymbol{\Sigma})$ con **misma** matriz $\boldsymbol{\Sigma}$:

$$f_i(\mathbf{x}) = \frac{1}{(2\pi)^{p/2}|\boldsymbol{\Sigma}|^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu}_i)'\boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu}_i)\right\}.$$

Bajo normalidad multivariante y covarianza común, la frontera de decisión se vuelve lineal en $\mathbf{x}$ usando las funciones:

$$\delta_i(\mathbf{x}) = \mathbf{x}'\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_i - \frac{1}{2}\boldsymbol{\mu}_i'\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_i + \log \pi_i, \qquad i = 1, 2.$$

Demostración. Partimos de la regla bayesiana $\arg\max_i\{\pi_i f_i(\mathbf{x})\}$. *Tomando logaritmos y sustituyendo la densidad normal multivariante con covarianza común:*

$$\log \pi_i - \frac{1}{2}(\mathbf{x}-\boldsymbol{\mu}_i)'\boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu}_i) - \frac{1}{2}\log|\boldsymbol{\Sigma}| - \frac{p}{2}\log(2\pi).$$

Los dos últimos términos no dependen de i, por lo que no afectan a la decisión. Al expandir el término cuadrático:

$$-\frac{1}{2}\mathbf{x}'\boldsymbol{\Sigma}^{-1}\mathbf{x} + \mathbf{x}'\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_i - \frac{1}{2}\boldsymbol{\mu}_i'\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_i + \log \pi_i.$$

El término $-\frac{1}{2}\mathbf{x}'\boldsymbol{\Sigma}^{-1}\mathbf{x}$ también es común a todas las clases. Eliminándolo se obtiene exactamente $\delta_i(\mathbf{x})$. □

Definición de variables (primera aparición). En esta expresión, $\delta_i(\mathbf{x})$ es función discriminante lineal de la clase i ; $\boldsymbol{\mu}_i$ es vector de medias de la clase i ; $\log \pi_i$ es ajuste por probabilidad a priori .

Se asigna al grupo con mayor $\delta_i(\mathbf{x})$.

Si $\pi_1 = \pi_2$ y costes iguales, equivale a clasificar por **distancia de Mahalanobis mínima** al centro:

$$D_i^2(\mathbf{x}) = (\mathbf{x}-\boldsymbol{\mu}_i)'\boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu}_i), \qquad \text{elegir } \arg\min_i D_i^2(\mathbf{x}).$$

Definición de variables (primera aparición). En esta expresión, $D_i^2(\mathbf{x})$ es distancia de Mahalanobis de $\mathbf{x}$ a la clase i .

Si $\boldsymbol{\Sigma} = \sigma^2\mathbf{I}$, la regla se reduce a distancia euclídea.

Con normalidad multivariante y matriz común, la regla con costes y priori puede

escribirse como:

$$D_1^2(\mathbf{x}) - D_2^2(\mathbf{x}) > 2\log\left(\frac{c(2|1)\pi_1}{c(1|2)\pi_2}\right) \implies \text{clasificar en } \mathcal{P}_2.$$

Esta expresión evidencia que el umbral de decisión se desplaza según costes y priori.

2.2.1. Probabilidad a posteriori en función de distancias

Para dos grupos:

$$P(\mathcal{P}_1 \mid \mathbf{x}) = \frac{1}{1 + \dfrac{\pi_2}{\pi_1}\exp\left[-\frac{1}{2}\left(D_2^2(\mathbf{x}) - D_1^2(\mathbf{x})\right)\right]}.$$

Cuanto menor sea D_1^2 frente a D_2^2, mayor será la probabilidad a posteriori de pertenecer a $\mathcal{P}_1$.

2.2.2. Estimación de parámetros en la práctica

En aplicaciones reales, π_g, $\boldsymbol{\mu}_g$ y $\boldsymbol{\Sigma}$ no son conocidos y se estiman en la muestra de entrenamiento:

$$\hat{\pi}_g = \frac{n_g}{n}, \qquad \hat{\boldsymbol{\mu}}_g = \frac{1}{n_g}\sum_{i:y_i=g}\mathbf{x}_i,$$

$$\hat{\boldsymbol{\Sigma}} = \frac{1}{n-G}\sum_{g=1}^{G}\sum_{i:y_i=g}(\mathbf{x}_i - \hat{\boldsymbol{\mu}}_g)(\mathbf{x}_i - \hat{\boldsymbol{\mu}}_g)'.$$

La regla empírica queda:

$$\hat{\delta}_g(\mathbf{x}) = \mathbf{x}'\hat{\boldsymbol{\Sigma}}^{-1}\hat{\boldsymbol{\mu}}_g - \frac{1}{2}\hat{\boldsymbol{\mu}}_g'\hat{\boldsymbol{\Sigma}}^{-1}\hat{\boldsymbol{\mu}}_g + \log\hat{\pi}_g,$$

asignando al grupo con mayor $\hat{\delta}_g(\mathbf{x})$.

2.2.3. Ejemplo numérico (dos pintores)

Se observan dos variables: profundidad de trazo y proporción del lienzo. Con medias:

$$\boldsymbol{\mu}_A = (2,\, 0.8)', \qquad \boldsymbol{\mu}_B = (2.3,\, 0.7)',$$

y matriz común

$$\boldsymbol{\Sigma} = \begin{pmatrix} 0.25 & 0.025 \\ 0.025 & 0.01 \end{pmatrix}, \quad \boldsymbol{\Sigma}^{-1} \approx \begin{pmatrix} 5.33 & -13.33 \\ -13.33 & 133.33 \end{pmatrix}.$$

Para $\mathbf{x}_0 = (2.1,\, 0.75)'$:

$$D_A^2(\mathbf{x}_0) \approx 0.520, \qquad D_B^2(\mathbf{x}_0) \approx 0.813.$$

Como $D_A^2 < D_B^2$, se clasifica en el grupo A. El ejemplo ilustra que la regla no se basa en distancia euclídea, sino en distancia reescalada por la estructura de covarianza común.

Si $\pi_A = \pi_B$:

$$P(A \mid \mathbf{x}_0) \approx \frac{1}{1 + \exp\left[-\frac{1}{2}(0.813 - 0.520)\right]} \approx 0.537.$$

La asignación es razonable, pero con incertidumbre apreciable.

2.2.4. Probabilidad teórica de error (caso simétrico)

En dos grupos normales con covarianza común, y con costes/priori iguales, si

$$\Delta^2 = (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)'\boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2),$$

la probabilidad de clasificación errónea en cada sentido es:

$$\boxed{P(2|1) = P(1|2) = 1 - \Phi\left(\frac{\Delta}{2}\right).}$$

En el ejemplo, $\Delta \approx 1.6166$, por lo que $1 - \Phi(\Delta/2) \approx 0.2095$ (error teórico alrededor del 21 %).

3. Generalización para varias poblaciones normales

Para G poblaciones, la región de decisión de la clase g es:

$$\mathcal{A}_g = \{\mathbf{x} \in \mathbb{R}^p : \ \pi_g f_g(\mathbf{x}) > \pi_i f_i(\mathbf{x}), \ \forall i \neq g\}.$$

Definición de variables (primera aparición). En esta expresión, G es número total de clases ; g es índice de clase ; $\mathcal{A}_g$ es región de decisión asignada a la clase g .

- Esta formulación compara simultáneamente todas las clases.
- También puede implementarse por comparaciones dos a dos entre poblaciones, pero la regla global anterior es la forma canónica.

Si f_g son normales con **covarianza común $\boldsymbol{\Sigma}$**:

$$\mathbf{X} \mid g \sim \mathcal{N}_p(\boldsymbol{\mu}_g, \boldsymbol{\Sigma}),$$

la regla es asignar al grupo con mayor:

$$\delta_g(\mathbf{x}) = \mathbf{x}'\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_g - \frac{1}{2}\boldsymbol{\mu}_g'\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_g + \log \pi_g.$$

Con priori iguales, equivale a minimizar $D_g^2(\mathbf{x})$.

3.1. Fronteras de decisión

La frontera entre grupos i, j se obtiene de $\delta_i(\mathbf{x}) = \delta_j(\mathbf{x})$, es decir, un **hiperplano**:

$$(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)'\boldsymbol{\Sigma}^{-1}\mathbf{x} - \frac{1}{2}\left(\boldsymbol{\mu}_i'\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_i - \boldsymbol{\mu}_j'\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_j\right) + \log\frac{\pi_i}{\pi_j} = 0.$$

Demostración. La igualdad $\delta_i(\mathbf{x}) = \delta_j(\mathbf{x})$ elimina los términos comunes de segundo grado en $\mathbf{x}$ (procedentes de $-\frac{1}{2}\mathbf{x}'\boldsymbol{\Sigma}^{-1}\mathbf{x}$), ya que la covarianza es compartida por todas las clases. Por ello, el contorno de indiferencia queda descrito por una ecuación afín en $\mathbf{x}$, es decir, un hiperplano. □

4. Función lineal de Fisher

4.1. Caso de dos grupos

El criterio de Fisher puede leerse como una reformulación geométrica del objetivo bayesiano gaussiano: hallar una proyección escalar $z = \boldsymbol{\alpha}'\mathbf{x}$ que maximice separación intergrupos relativa a dispersión intragrupo.

Con medias muestrales $\bar{\mathbf{x}}_1, \bar{\mathbf{x}}_2$ y matriz intra-grupos agrupada $\mathbf{S}_w$, el criterio es:

$$J(\boldsymbol{\alpha}) = \frac{\left[\boldsymbol{\alpha}'(\bar{\mathbf{x}}_2 - \bar{\mathbf{x}}_1)\right]^2}{\boldsymbol{\alpha}'\mathbf{S}_w\boldsymbol{\alpha}}, \qquad \boldsymbol{\alpha} \propto \mathbf{S}_w^{-1}(\bar{\mathbf{x}}_2 - \bar{\mathbf{x}}_1).$$

Definición de variables (primera aparición). En esta expresión, $\boldsymbol{\alpha}$ es dirección de proyección discriminante de Fisher ; $J(\boldsymbol{\alpha})$ es cociente entre separación intergrupos y dispersión intragrupo ; $\mathbf{S}_w$ es matriz de dispersión intra-grupos agrupada .

Demostración. Definamos $\mathbf{d} = \bar{\mathbf{x}}_2 - \bar{\mathbf{x}}_1$. Maximizar $J(\boldsymbol{\alpha})$ equivale a maximizar $(\boldsymbol{\alpha}'\mathbf{d})^2$ bajo la restricción $\boldsymbol{\alpha}'\mathbf{S}_w\boldsymbol{\alpha} = 1$. Con multiplicadores de Lagrange:

$$\mathcal{L} = (\boldsymbol{\alpha}'\mathbf{d})^2 - \lambda(\boldsymbol{\alpha}'\mathbf{S}_w\boldsymbol{\alpha} - 1)\,.$$

La condición de primer orden conduce a $\mathbf{d}\mathbf{d}'\boldsymbol{\alpha} = \lambda\mathbf{S}_w\boldsymbol{\alpha}$, cuyo vector propio no nulo es proporcional a $\mathbf{S}_w^{-1}\mathbf{d}$. Por tanto, $\boldsymbol{\alpha} \propto \mathbf{S}_w^{-1}(\bar{\mathbf{x}}_2 - \bar{\mathbf{x}}_1)$. □

Así, la dirección discriminante coincide con la dirección que maximiza la distancia de Mahalanobis entre los centroides proyectados.

- Si $\mathbf{S}_w = \mathbf{I}$, la dirección es paralela al vector que une medias (distancia euclídea).
- Con costes y priori iguales, en el eje proyectado se usa como umbral el punto medio entre medias proyectadas.

4.2. Caso de varios grupos

Para G grupos se buscan $r = \text{mín}(p, G-1)$ variables canónicas:

$$z_j = \mathbf{u}_j'\mathbf{x}, \qquad j = 1, \ldots, r,$$

que maximizan separación entre grupos y minimizan dispersión intragrupos.
Definimos:

$$\mathbf{W} = \sum_{g=1}^{G} \sum_{i=1}^{n_g} (\mathbf{x}_{ig} - \bar{\mathbf{x}}_g)(\mathbf{x}_{ig} - \bar{\mathbf{x}}_g)',$$

$$\mathbf{B} = \sum_{g=1}^{G} n_g (\bar{\mathbf{x}}_g - \bar{\mathbf{x}})(\bar{\mathbf{x}}_g - \bar{\mathbf{x}})'.$$

Definición de variables (primera aparición). En esta expresión, $\mathbf{W}$ es matriz de dispersión intra-grupos ; $\mathbf{B}$ es matriz de dispersión entre grupos ; n_g es tamaño muestral del grupo g ; $\mathbf{u}$ es dirección canónica candidata .

Cada dirección se obtiene maximizando:

$$\phi(\mathbf{u}) = \frac{\mathbf{u}'\mathbf{B}\mathbf{u}}{\mathbf{u}'\mathbf{W}\mathbf{u}},$$

lo que conduce al problema de autovalores:

$$\mathbf{B}\mathbf{u} = \lambda \mathbf{W}\mathbf{u} \quad \Longleftrightarrow \quad \mathbf{W}^{-1}\mathbf{B}\mathbf{u} = \lambda \mathbf{u}.$$

Definición de variables (primera aparición). En esta expresión, λ es autovalor asociado a una dirección canónica .

Los autovectores asociados a los mayores autovalores proporcionan las variables canónicas más discriminantes.

5. Variables canónicas discriminantes

Sea $\mathbf{U}_r = [\mathbf{u}_1, \ldots, \mathbf{u}_r]$. Para una observación $\mathbf{x}$:

$$\mathbf{z} = \mathbf{U}_r'\mathbf{x} \in \mathbb{R}^r.$$

- $\mathbf{z}$ son las coordenadas en el espacio discriminante.
- Cada grupo tiene centroide canónico $\bar{\mathbf{z}}_g = \mathbf{U}_r'\bar{\mathbf{x}}_g$.
- Una regla práctica de clasificación es asignar $\mathbf{z}_0$ al centroide más próximo (normalmente distancia euclídea en ese espacio).

Geométricamente, la transformación canónica busca un espacio de dimensión baja donde los centroides queden lo más separados posible con métrica intragrupo.

Observación. Las variables canónicas quedan ordenadas por potencia discriminante (autovalores decrecientes) y son incorreladas respecto a la métrica intra-grupos.

6. Evaluación del modelo: matriz de confusión

Definición 6.1 (Matriz de confusión)**.** En clasificación binaria, una matriz de confusión recoge:

- VP (verdaderos positivos), VN (verdaderos negativos), FP (falsos positivos), FN (falsos negativos).
- Según la convención habitual en aprendizaje automático: filas = clase real, columnas = clase predicha (algunos programas usan la convención traspuesta).

Métricas más usadas:

$$\text{Exactitud} = \frac{VP + VN}{VP + VN + FP + FN},$$

$$\text{Precisión (PPV)} = \frac{VP}{VP + FP}, \qquad \text{Sensibilidad (Recall)} = \frac{VP}{VP + FN},$$

$$\text{Especificidad} = \frac{VN}{VN + FP}, \qquad \text{VPN} = \frac{VN}{VN + FN},$$

$$F_1 = \frac{2\,\text{Precisión} \cdot \text{Sensibilidad}}{\text{Precisión} + \text{Sensibilidad}} = \frac{2VP}{2VP + FP + FN}.$$

- Tasa de falsos positivos: $\dfrac{FP}{FP + VN} = 1 - \text{Especificidad}$.
- Tasa de falsos negativos: $\dfrac{FN}{FN + VP} = 1 - \text{Sensibilidad}$.

Nota. Cuando las clases están desbalanceadas, conviene no evaluar solo con exactitud; deben reportarse también sensibilidad, especificidad, precisión y F_1, idealmente junto con validación cruzada estratificada.

7. Estudio de las dimensiones necesarias

No siempre se necesitan las $r = \text{mín}(p, G - 1)$ dimensiones canónicas. Para decidir cuántas conservar:

1. Ordenar autovalores $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_r$ de $\mathbf{W}^{-1}\mathbf{B}$.
2. Evaluar proporción acumulada de discriminación:

$$\eta_q = \frac{\sum_{j=1}^{q} \lambda_j}{\sum_{j=1}^{r} \lambda_j}.$$

3. Contrastar significación global o secuencial (p. ej. mediante estadísticos tipo Lambda de Wilks).

Si normalizamos los autovectores para que $\mathbf{v}_j'\mathbf{W}\mathbf{v}_j = 1$, entonces:

$$\mathbf{v}_j'\mathbf{B}\mathbf{v}_j = \lambda_j,$$

de forma que cada λ_j cuantifica la separación adicional aportada por la dimensión canónica j.

8. Algunas consideraciones prácticas

8.1. Hipótesis de partida

Supuestos clásicos del ADL:

- Normalidad multivariante dentro de cada grupo.
- Matriz de covarianzas común entre grupos ($\mathbf{\Sigma}_1 = \cdots = \mathbf{\Sigma}_G$).
- Independencia muestral y ausencia de colinealidad extrema.

Estas hipótesis no deben leerse como formalidad: delimitan el régimen donde la regla lineal es teóricamente óptima. Su comprobación condiciona la validez del modelo y la interpretación de resultados.

Si la homogeneidad de covarianzas falla claramente, suele considerarse QDA. Si la normalidad es débil, pueden funcionar bien transformaciones y/o métodos no paramétricos.

- Para evaluar homogeneidad de covarianzas se utiliza con frecuencia el test de **Box's M** (con cautela en muestras pequeñas).
- Si p es grande respecto a n, conviene regularizar la matriz de covarianzas (*shrinkage LDA*) para mejorar estabilidad y generalización.

8.2. Tamaño muestral

- Regla práctica habitual: al menos 5 observaciones por predictor.
- Es recomendable que el grupo más pequeño tenga tamaño superior al número de predictores.
- Como guía operativa, se buscan al menos 20 observaciones por grupo para mayor estabilidad.
- Desbalances fuertes entre tamaños de grupo pueden sesgar la regla de clasificación hacia los grupos más frecuentes si no se corrigen las probabilidades a priori o los pesos de coste.

Resumen operativo del Tema 4:

1. Modelar $P(g \mid \mathbf{x})$ mediante Bayes y densidades de grupo.
2. En LDA, usar funciones discriminantes lineales (o equivalentes por Mahalanobis).
3. Para varios grupos, construir variables canónicas con $\mathbf{W}^{-1}\mathbf{B}$.

4. Evaluar siempre la clasificación con matriz de confusión y métricas más allá de la exactitud.

Formulario Final

Tema 1: Introducción y Álgebra Lineal

Valor teórico (combinación lineal):

$$z = w_1 X_1 + w_2 X_2 + \cdots + w_p X_p.$$

Matriz de datos:

$$\mathbf{X} = [x_{ij}]_{n \times p}.$$

Producto escalar:

$$\mathbf{x}'\mathbf{y} = \sum_i x_i y_i.$$

Norma euclídea:

$$\|\mathbf{x}\| = \sqrt{\mathbf{x}'\mathbf{x}}.$$

Relación producto escalar–ángulo:

$$\mathbf{x}'\mathbf{y} = \|\mathbf{x}\| \, \|\mathbf{y}\| \cos\theta.$$

Ecuación característica (autovalores):

$$|\mathbf{A} - \lambda \mathbf{I}| = 0.$$

Forma cuadrática:

$$Q(\mathbf{x}) = \mathbf{x}'\mathbf{A}\mathbf{x} = \sum_i a_{ii} x_i^2 + \sum_{i<j} (a_{ij} + a_{ji}) x_i x_j.$$

Inversa de matriz regular:

$$\mathbf{A}^{-1} = \frac{1}{|\mathbf{A}|} \mathbf{A}^{\Lambda}.$$

Tema 2: Distribuciones Multivariantes

Distribución conjunta (función de distribución):

$$F(\mathbf{x}^0) = P(\mathbf{x} \leq \mathbf{x}^0).$$

Paso de densidad a distribución:

$$F(\mathbf{x}^0) = \int_{-\infty}^{\mathbf{x}^0} f(\mathbf{x}) \, d\mathbf{x}.$$

Distribución condicionada:

$$f(\mathbf{x}_1 \mid \mathbf{x}_2^0) = \frac{f(\mathbf{x}_1, \mathbf{x}_2^0)}{f(\mathbf{x}_2^0)}.$$

Independencia:

$$f(\mathbf{x}_1, \ldots, \mathbf{x}_p) = \prod_{j=1}^{p} f(\mathbf{x}_j).$$

Vector de medias:

$$\boldsymbol{\mu} = E(\mathbf{X}), \qquad \bar{\mathbf{x}} = \frac{1}{n}\sum_{i=1}^{n} \mathbf{x}_i.$$

Matriz de varianzas–covarianzas:

$$\mathbf{S} = \frac{1}{n}\sum_{i=1}^{n}(\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})'.$$

Matriz de centrado y proyección:

$$\tilde{\mathbf{X}} = \mathbf{P}\mathbf{X}, \qquad \mathbf{P} = \mathbf{I} - \frac{1}{n}\mathbf{1}\mathbf{1}'.$$

Correlación lineal simple:

$$r_{jk} = \frac{s_{jk}}{s_j s_k}.$$

Correlación parcial:

$$r_{jk.\,\mathrm{resto}} = -\frac{s^{jk}}{\sqrt{s^{jj}s^{kk}}}.$$

Cambio de variable (jacobiano):

$$f_y(\mathbf{y}) = f_x(\mathbf{x})\left|\frac{d\mathbf{x}}{d\mathbf{y}}\right|.$$

Transformación lineal:

$$\boldsymbol{\mu}_y = \mathbf{A}\boldsymbol{\mu}_x, \qquad \mathbf{S}_y = \mathbf{A}\mathbf{S}_x\mathbf{A}'.$$

Multinomial:

$$P(\mathbf{n}) = \frac{n!}{n_1!\cdots n_G!}\, p_1^{n_1}\cdots p_G^{n_G}.$$

Dirichlet:

$$f(x_1, \ldots, x_{G-1}) = \frac{\Gamma(\alpha_0)}{\prod_{i=1}^{G}\Gamma(\alpha_i)}\prod_{i=1}^{G} x_i^{\alpha_i - 1}.$$

Normal multivariante:

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{p/2}|\boldsymbol{\Sigma}|^{1/2}}\exp\left\{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})'\boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu})\right\}.$$

Normal condicionada (bloques):

$$\mathbf{X}_1 \mid \mathbf{X}_2 = \mathbf{x}_2 \sim \mathcal{N}\Big(\boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2),\ \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}\Big).$$

Distancia de Mahalanobis y ley χ^2:

$$D^2 = (\mathbf{X} - \boldsymbol{\mu})'\boldsymbol{\Sigma}^{-1}(\mathbf{X} - \boldsymbol{\mu}) \sim \chi^2(p).$$

Tema 3: Componentes Principales (ACP)

Criterio geométrico básico:

$$\text{mín} \sum_{i=1}^{n} r_i^2 \Longleftrightarrow \text{máx} \sum_{i=1}^{n} z_i^2.$$

Definición de componentes:

$$\mathbf{Z} = \mathbf{X}\mathbf{A}, \qquad \mathbf{A}'\mathbf{A} = \mathbf{I}.$$

Varianza del componente j:

$$\text{var}(\mathbf{z}_j) = \mathbf{a}_j'\mathbf{S}\mathbf{a}_j.$$

Problema de autovalores ACP:

$$\mathbf{S}\mathbf{a}_j = \lambda_j \mathbf{a}_j, \qquad |\mathbf{S} - \lambda\mathbf{I}| = 0.$$

Incorrelación entre componentes:

$$\text{cov}(\mathbf{z}_i, \mathbf{z}_j) = 0 \quad (i \neq j).$$

Conservación de varianza total:

$$\text{tr}(\mathbf{S}) = \sum_{j=1}^{p} \lambda_j = \sum_{j=1}^{p} \text{var}(z_j).$$

Proporción explicada por componente:

$$c_h = \frac{\lambda_h}{\sum_{j=1}^{p} \lambda_j}.$$

Correlación componente–variable:

$$r(z_i, x_j) = a_{ij}\frac{\sqrt{\lambda_i}}{s_j}.$$

Matriz de saturaciones (cargas factoriales):

$$\mathbf{F} = \mathbf{A}\boldsymbol{\Lambda}^{1/2}.$$

ACP sobre correlaciones (análisis normado):

$$\sum_{j=1}^{p} \lambda_j^R = \operatorname{tr}(\mathbf{R}) = p, \qquad c_j = \frac{\lambda_j^R}{p}.$$

Tema 4: Análisis Discriminante (LDA/Fisher)

Función discriminante lineal (dos clases):

$$z_k = a + w_1 x_{1k} + \cdots + w_p x_{pk}.$$

Posterior bayesiana (dos clases):

$$P(\mathcal{P}_i \mid \mathbf{x}_0) = \frac{\pi_i f_i(\mathbf{x}_0)}{\pi_1 f_1(\mathbf{x}_0) + \pi_2 f_2(\mathbf{x}_0)}.$$

Regla con costes de clasificación:

$$c(1|2)\,\pi_2 f_2(\mathbf{x}_0) > c(2|1)\,\pi_1 f_1(\mathbf{x}_0) \Longrightarrow \text{clasificar en } \mathcal{P}_2.$$

Discriminantes lineales gaussianos (covarianza común):

$$\delta_i(\mathbf{x}) = \mathbf{x}'\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_i - \frac{1}{2}\boldsymbol{\mu}_i'\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_i + \log \pi_i.$$

Distancia de Mahalanobis por grupo:

$$D_i^2(\mathbf{x}) = (\mathbf{x} - \boldsymbol{\mu}_i)'\boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}_i).$$

Posterior en función de distancias (dos grupos):

$$P(\mathcal{P}_1 \mid \mathbf{x}) = \frac{1}{1 + \dfrac{\pi_2}{\pi_1}\exp\left[-\frac{1}{2}\left(D_2^2(\mathbf{x}) - D_1^2(\mathbf{x})\right)\right]}.$$

Estimadores muestrales en LDA:

$$\hat{\pi}_g = \frac{n_g}{n}, \qquad \hat{\boldsymbol{\mu}}_g = \frac{1}{n_g}\sum_{i:y_i=g} \mathbf{x}_i, \qquad \hat{\boldsymbol{\Sigma}} = \frac{1}{n-G}\sum_{g=1}^{G}\sum_{i:y_i=g}(\mathbf{x}_i - \hat{\boldsymbol{\mu}}_g)(\mathbf{x}_i - \hat{\boldsymbol{\mu}}_g)'.$$

Error teórico simétrico (dos gaussianas):

$$\Delta^2 = (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)'\boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2), \qquad P(2|1) = P(1|2) = 1 - \Phi\left(\frac{\Delta}{2}\right).$$

Región de decisión multiclase:

$$\mathcal{A}_g = \{\mathbf{x} \in \mathbb{R}^p : \pi_g f_g(\mathbf{x}) > \pi_i f_i(\mathbf{x}),\ \forall i \neq g\}.$$

Frontera lineal entre clases i, j:

$$(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)'\boldsymbol{\Sigma}^{-1}\mathbf{x} - \frac{1}{2}\Big(\boldsymbol{\mu}_i'\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_i - \boldsymbol{\mu}_j'\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_j\Big) + \log\frac{\pi_i}{\pi_j} = 0.$$

Criterio de Fisher (dos grupos):

$$J(\boldsymbol{\alpha}) = \frac{\left[\boldsymbol{\alpha}'(\bar{\mathbf{x}}_2 - \bar{\mathbf{x}}_1)\right]^2}{\boldsymbol{\alpha}'\mathbf{S}_w\boldsymbol{\alpha}}, \qquad \boldsymbol{\alpha} \propto \mathbf{S}_w^{-1}(\bar{\mathbf{x}}_2 - \bar{\mathbf{x}}_1).$$

Dispersión intra/intergrupo y problema generalizado:

$$\mathbf{W} = \sum_{g=1}^{G}\sum_{i=1}^{n_g}(\mathbf{x}_{ig} - \bar{\mathbf{x}}_g)(\mathbf{x}_{ig} - \bar{\mathbf{x}}_g)', \quad \mathbf{B} = \sum_{g=1}^{G} n_g(\bar{\mathbf{x}}_g - \bar{\mathbf{x}})(\bar{\mathbf{x}}_g - \bar{\mathbf{x}})',$$

$$\mathbf{B}\mathbf{u} = \lambda\mathbf{W}\mathbf{u} \Longleftrightarrow \mathbf{W}^{-1}\mathbf{B}\mathbf{u} = \lambda\mathbf{u}.$$

Variables canónicas y número máximo:

$$\mathbf{z} = \mathbf{U}_r'\mathbf{x}, \qquad r = \text{mín}(p, G-1).$$

Proporción acumulada de discriminación:

$$\eta_q = \frac{\sum_{j=1}^{q}\lambda_j}{\sum_{j=1}^{r}\lambda_j}.$$

Métricas de clasificación (matriz de confusión):

$$\text{Exactitud} = \frac{VP + VN}{VP + VN + FP + FN}, \tag{12}$$

$$\text{Precisión} = \frac{VP}{VP + FP}, \tag{13}$$

$$\text{Sensibilidad} = \frac{VP}{VP + FN}, \tag{14}$$

$$\text{Especificidad} = \frac{VN}{VN + FP}, \tag{15}$$

$$F_1 = \frac{2VP}{2VP + FP + FN}. \tag{16}$$